XXIII Colóquio PEQ/COPPE (04/11/2026)

Todo o texto deste documento foi gerado pelo Claude, da Anthropic, a partir da legenda automática do YouTube extraída por meio do DownSub. Nomes, números e referências a artigos devem ser confirmados contra os slides ou as publicações originais antes de citação acadêmica.

Sumário

1. Sobre a gravação e a transcrição
2. Estrutura do evento
    - 2.1 Comparação com a programação oficial
3. Índice cronológico
    - 3.1 Abertura
    - 3.2 Keynote — Álvaro Coutinho
    - 3.3 Palestra — Henrique Pacheco
    - 3.4 Palestra — Amanda Lemette
    - 3.5 Palestra — Rafael Mesquita
4. Síntese por palestra
    - 4.1 Cerimônia de abertura
    - 4.2 Álvaro Coutinho — Aprendizado de máquina científico
    - 4.3 Henrique Pacheco — ML no screening de catalisadores
    - 4.4 Amanda Lemette — Diagnóstico de falhas e modelagem híbrida
    - 4.5 Rafael Mesquita — IA na engenharia de enzimas
5. Glossário de conceitos de IA e Machine Learning
    - 5.1 Fundamentos e arquiteturas
    - 5.2 Operadores neurais e redução de ordem
    - 5.3 Treinamento, métricas e diagnóstico
    - 5.4 Agentes, LLMs e infraestrutura
    - 5.5 Ferramentas e bases de dados nomeadas
6. Padrões transversais e conclusões do dia
    - 6.1 Conceitos que reaparecem em mais de uma palestra
    - 6.2 Observações finais sobre o material
7. Fontes

1. Sobre a gravação e a transcrição

O vídeo completo do evento, publicado pelo canal Auditorio COPPE em 04/11/2026 sob o título "XXIII - Colóquio de Engenharia Química - PEQ/COPPE/UFRJ - 04/11/26", tem 7:07:05. O arquivo de legendas usado nesta síntese cobre um intervalo um pouco menor: a primeira legenda está em 00:02:45 e a última termina em 06:58:25, e os cerca de 9 minutos finais do vídeo não têm fala legendada. Desse total, apenas 4 h 44 min contêm fala; o restante são intervalos sem áudio útil.

A gravação registra continuamente um dia de colóquio, com quatro palestras completas, a cerimônia de abertura e as sessões de perguntas. A gravação cobre **um único eixo temático** (Fronteiras da Pesquisa e Desenvolvimento), porque o dia 04/11 foi inteiramente dedicado a ele; os demais eixos do colóquio ocorreram em outros dias.

Os silêncios longos marcam a estrutura do dia e são úteis como balizas. Coffee breaks, almoço e sessão de pôsteres aconteceram fora do auditório das palestras, de modo que a gravação seguiu registrando a sala nesses intervalos:

Intervalo no vídeo	Duração	O que é
00:41:15 – 00:59:00	18 min	Coffee break da manhã, fora do auditório
01:00 – 01:13	~13 min	Preparação técnica do auditório para a keynote
03:31:17 – 04:47:45	1 h 16 min	Almoço, fora do auditório
05:44:00 – 05:57:08	13 min	Intervalo antes da última palestra; público visitou os pôsteres

Duas ressalvas sobre a qualidade do material. A legenda é automática e corrompe sistematicamente nomes próprios e termos técnicos: "PEC" por PEQ, "COP" por COPPE, "Lemet" por Lemette, "cloud" por Claude, "redes neuronais" alternando com "redesorais", "Haller Benar" por Rayleigh–Bénard, "bolts" por Boltz, e "PIN", "Pim", "PCIN" ou "Pecin" por PINN ou PCINN conforme o contexto (conferido nos slides da palestra). Esses termos foram reconstruídos pelo contexto; nomes de ferramentas cuja grafia não pôde ser confirmada foram omitidos, e participantes que não se identificaram na gravação são mencionados sem nome. Além disso, as legendas registram apenas a fala: nenhum slide, gráfico ou equação foi capturado, de modo que resultados numéricos aparecem aqui só quando o palestrante os leu em voz alta.

Os tempos do vídeo não correspondem ao horário do evento. Pela conversa dos organizadores em 00:59 (relógios marcando 9h45) e pelo início da abertura, o deslocamento é de cerca de **+8h47**: tempo do vídeo mais 8h47 ≈ hora local.

2. Estrutura do evento

O dia gravado tem seis blocos. O tema geral do XXIII Colóquio é "Engenharia Química na Era da IA: inovação, sustentabilidade e formação". O colóquio foi dividido em quatro eixos temáticos, e o dia 04/11 foi dedicado ao eixo Fronteiras da Pesquisa e Desenvolvimento.

Bloco	Tempo no vídeo	Quem	Título oficial ou tema
Cerimônia de abertura	00:08:18 – 00:41:15	Frederico Kronemberger (coord. PEQ), Suzana Kahn (dir. COPPE), João Ramos Torres (pró-reitor de pós-graduação e pesquisa, UFRJ); apresentação de Renata	Trajetória do PEQ, os três eixos do tema (inovação, sustentabilidade, formação) e o lugar da IA neles
Keynote do eixo 1	01:13:30 – 02:21:00	Álvaro Coutinho (COPPE/UFRJ, NACAD)	*Recent Advances in Scientific Machine Learning for Coupled Flow and Transport*
Palestra 1 do eixo 1	02:22:02 – 03:30:30	Henrique Poltronieri Pacheco (PEQ/COPPE)	Machine Learning aplicado ao *screening* de materiais
Palestra 2 do eixo 1	04:47:45 – 05:44:00	Amanda Lemette (PUC-Rio, grupo GAAP)	IA aplicada à Engenharia de Sistemas de Processos: experiências em diagnóstico de falhas e modelagem híbrida
Palestra 3 do eixo 1	05:57:08 – 06:55:49	Rafael Dias Mesquita (IQ/UFRJ, LabInfo)	Uso de IA na engenharia de enzimas
Encerramento do dia	06:58:18 – 06:58:25	Mediador da sessão	Foto do grupo, liberação do coffee break e chamada para a sessão de pôsteres

Rui de Paula, do PEQ e da comissão organizadora, abriu o eixo e mediou as sessões da manhã e a palestra de Amanda Lemette, lendo as minibiografias e conduzindo as perguntas. Na sessão de Rafael Mesquita e no encerramento do dia, o mediador não é identificado pelo nome na legenda.

2.1 Comparação com a programação oficial

A programação oficial do dia 04/11 coincide com o que a gravação mostra: mesa de abertura, keynote e três palestras do eixo Fronteiras da Pesquisa e Desenvolvimento, além de coffee breaks, almoço e sessão de pôsteres (todos os eixos), estes fora do auditório. Os demais eixos temáticos do colóquio — Automação e Gêmeos Digitais, Educação e Ética, e Modelagem Híbrida — ocorreram em outros dias e não fazem parte desta gravação.

Na mesa de abertura, a Reitoria da UFRJ foi representada pelo pró-reitor de pós-graduação e pesquisa, João Ramos Torres. Antes da última palestra, o mediador anunciou em 05:43 um intervalo de cerca de 10 minutos, aproveitado pelo público para visitar os pôsteres.

Uma palestra de outro dia aparece apenas como menção: durante a sessão de perguntas de Henrique (03:24), comenta-se que a questão de integridade em pesquisa seria tratada mais adiante no colóquio — tema da palestra de Renan Moritz Almeida, do eixo Educação e Ética.

3. Índice cronológico

Tempos no formato HH:MM:SS, iguais aos do vídeo no YouTube. A hora local aproximada corresponde ao tempo do vídeo acrescido de 8h47.

3.1 Abertura

Tempo	Conteúdo
00:08:18	Boas-vindas; histórico do PEQ; anúncio do tema do colóquio
00:10:00	Composição da mesa de honra
00:11:46	Hino Nacional
00:15:01	Frederico Kronemberger: PEQ fundado em 1963 por Alberto Luiz Coimbra; nota 7 na CAPES; colóquio realizado desde 2001
00:18:40	Kronemberger sobre IA: engenharia química sempre foi dados e modelos; a base e o senso crítico não são substituíveis
00:23:45	Suzana Kahn: finitude de recursos, desmaterialização da economia, transição tecnológica mais do que energética, *spin-offs* e *deep tech*
00:31:02	João Ramos Torres: impacto assimétrico da IA entre matemática e ciências experimentais; questões éticas no ensino; produtividade
00:40:30	Encerramento da cerimônia; anúncio do coffee break

3.2 Keynote — Álvaro Coutinho

Tempo	Conteúdo
01:13:30	Apresentação do eixo 1 e minibiografia do palestrante
01:15:30	Área interdisciplinar de Engenharia e Ciência Computacional; supercomputador Lobo Carneiro e sua substituição
01:18:00	Onde a simulação de alta fidelidade encontra o aprendizado de máquina: o *outer loop* de otimização, quantificação de incerteza e projeto
01:20:00	Complexidade assintótica ótima; multigrid como único método que a atinge
01:22:00	Por que SciML não é tratamento de imagem: verificação das hipóteses físicas
01:24:40	Problema 1 — correntes de turbidez; DMD com malhas adaptativas; projeção L2 em malha de referência; aceleração de 230×

Tempo	Conteúdo
01:34:10	Problema paramétrico: inclinação do canal via rotação do vetor gravidade; SVD + *autoencoder*; espaço latente de dimensão 16; acelerações de 500× a 10.000×
01:38:50	Problema 2 — Rayleigh–Bénard; limite da redução linear e largura de Kolmogorov; VAE; ortogonalidade como via de explicabilidade; balanceamento da *loss* como otimização multiobjetivo
01:49:40	Problema 3 — operadores neurais (FNO e DeepONet) para famílias de soluções; barreira de memória em GPU de 94 GB e a arquitetura híbrida que a contorna
02:00:40	Agentes de IA gerando *decks* de entrada do GEOS para sequestro de CO_2; 343 mil *tokens* por rodada; três execuções independentes convergindo
02:06:40	Redes neurais em grafo para malhas não estruturadas; visão integrada (HPC → métodos numéricos → SciML → agentes)
02:10:30	Perguntas: terceirização da revisão bibliográfica (Júlia); memória e esquecimento no treino de agentes (Felipe); GNN e variantes do DMD (Gustavo)

3.3 Palestra — Henrique Pacheco

Tempo	Conteúdo
02:22:02	Minibiografia; proposta de trazer a perspectiva do experimentalista
02:25:30	Linha do tempo do laboratório: CATS (2022) e a parceria com o INT sobre despolimerização de lignina
02:29:40	O custo como motivação: o exemplo do sal de rutênio a R$ 7.000
02:32:30	"Fazer o experimento sem fazer o experimento"; limitações da literatura; o problema de ontologia
02:36:40	CATS: três reações clássicas, ~245 artigos, ~15 mil linhas, saída única (conversão); $R^2 \approx 0{,}9$
02:38:10	Análise de sensibilidade: temperatura como *feature* dominante na reforma a vapor do metano
02:40:10	A pergunta retida: de onde vem a base de dados
02:44:30	Lignina: 120 artigos, 722 experimentos, 20 a 65 variáveis, otimização bayesiana com Optuna; R^2 de 0,5 a 0,6
02:50:30	Por que o desempenho caiu: *cluster* de dados abaixo de 30% de rendimento e esparsidade fora dele
02:53:50	**O resultado contraintuitivo**: o solvente polar aprótico pesa mais que o metal ativo

Tempo	Conteúdo
02:55:40	Consequência prática: o projeto migrou para triagem de solventes e passou a romper a barreira dos 30%
02:57:40	Terceira frente: agentes LLM lendo PDFs (texto, tabela e figura) para montar bases de dados
03:01:20	Agentes implementados: catalisador, metal–suporte, normalização ontológica
03:04:40	Métricas de extração comparando LLMs; alucinação e omissão como falso positivo e falso negativo
03:09:20	*Takeaways*: garbage in, garbage out; heterogeneidade e esparsidade; padrões ocultos; a decisão é do pesquisador
03:12:20	Perguntas: granularidade da síntese do catalisador (Miguel); normalização manual (Juan); problema inverso e assinaturas de IA (Igor); confiabilidade do artigo de origem (Ana); *guardrails* (Felipe); histórico de redes neurais no NUCAT desde 1993 (Maurício)

3.4 Palestra — Amanda Lemette

Tempo	Conteúdo
04:47:45	Minibiografia; apresentação do grupo GAAP (PUC-Rio)
04:50:10	Motivação: Bhopal (1984) e a falha como efeito dominó
04:53:40	Detecção versus diagnóstico de falhas
04:55:30	Base de dados Tennessee Eastman: 52 variáveis, 20 falhas, ~5 milhões de pontos
04:58:50	Transformação de séries temporais em imagens (GASF) e rede convolucional
05:01:00	Quatro frentes de aprofundamento do modelo; ~90% de acerto e superação da literatura
05:03:40	Falhas 3, 9, 10 e 15 que a rede confunde, e por quê
05:06:00	Transição: o problema oposto, quando faltam dados
05:08:20	PCINN e sua diferença em relação à PINN; pontos de colocação e derivada teórica do modelo físico
05:13:30	Caso 1 (Letícia): copolimerização etileno–decadieno, 14 experimentos, validação cruzada; superação do modelo cinético e da MLP pura
05:20:30	Caso 2 (Alexandre): PBS em suspensão; a dispersividade travada em 2 e as perdas adicionais de monotonicidade e de dispersividade
05:30:00	Conclusões: lapidar o modelo em vez de trocá-lo; o modelo fenomenológico dá a

Tempo	Conteúdo
	forma, o dado corrige
05:33:20	Perguntas: custo computacional (5 h de treino para a CNN, quase nulo para a PCINN); PINN e PCINN combinadas por região de confiança; até onde investir no modelo físico antes de recorrer a dados

3.5 Palestra — Rafael Mesquita

Tempo	Conteúdo
05:57:08	Minibiografia; aviso de que a visão é de usuário, não de desenvolvedor
06:00:50	IA como software treinado; LLMs e modelos de decisão por alternativas
06:04:00	Modelos de linguagem de proteínas (ESM); UniRef50 e UniRef90 como entrada
06:06:00	*Embeddings* explicados pela analogia do formulário de elegância
06:07:30	O que não precisa ser informado: polaridade, raio atômico, eletronegatividade
06:11:00	Histórico dos modelos ESM e a exigência de memória de GPU
06:12:40	Dimensão 1 — pH ótimo: EpHod, 9 mil enzimas e 2,2 milhões de sequências por pH ambiental; o viés em torno de pH 7
06:16:10	Teste próprio de troca de ESM1 por ESM3; ganho no pH neutro, perda em pH 10
06:19:20	Adoção de uma IA com melhor desempenho; a limitação de ±0,5 unidade de pH
06:25:00	Dimensão 2 — termoestabilidade: RaSP, mutação por força bruta, comparação com Rosetta
06:28:00	Dimensão 3 — afinidade: Boltz-2, entrada por sequência e SMILES, ~1000× mais rápido que FEP
06:36:20	A precisão média de 0,025 e a necessidade de controles por proteína
06:37:40	Validação em caso real: controle positivo por tamanho de cadeia carbônica e controle negativo com enzima homóloga inativa
06:41:40	Limitações do Boltz-2: regiões desordenadas, cofatores, múltiplos ligantes
06:43:00	Conclusões: avalie erro e precisão, faça controles, nunca trate o resultado como verdade absoluta
06:44:40	Perguntas: anticorpos e requisitos de hardware (mediador); o que fazer depois do palpite (Júlia); condições físico-químicas ausentes do treino; engenharia reversa dos *embeddings*

4. Síntese por palestra

4.1 Cerimônia de abertura

Ideia central. A IA não representa ruptura epistemológica para a engenharia química, e sim uma ferramenta nova sobre uma prática que sempre foi feita de dados e modelos — e por isso a aposta formativa deve ser nos fundamentos, não na ferramenta.

Kronemberger constrói o argumento em três passos. Primeiro, situa o PEQ historicamente: fundado em 1963 por Alberto Luiz Coimbra, embrião da COPPE, com a máxima avaliação da CAPES nos 50 anos em que a avaliação existe, e com o colóquio realizado desde 2001 como prestação de contas à sociedade, e não apenas como vitrine. Segundo, relativiza a novidade: se IA é uso de dados e aplicação de modelos, isso é exatamente o que a disciplina faz. Terceiro, articula os três eixos do tema em cadeia causal: a IA facilita a inovação, a inovação viabiliza processos mais sustentáveis (energia, água, carbono), e a formação é apontada como o eixo mais importante, por ser o papel central do programa. Fecha com a analogia da transferência de massa: entender o processo, usar a ferramenta para resolver as equações, interpretar o resultado com critério — na era de respostas fáceis, a base importa tanto ou mais.

Suzana Kahn desloca o foco para a materialidade. Seu ponto mais original: o que se vive não é tanto uma transição energética quanto uma transição tecnológica, e a nova fronteira da energia é tecnológica. Disso decorre a tese da desmaterialização da economia — produzir o mesmo com menos recurso natural — que coloca a engenharia química (catálise, enzimas, química circular, biorrefinarias) no centro. Acrescenta uma agenda institucional: *spin-offs* e *deep tech*, que, diferentemente de um aplicativo, exigem laboratório, e por isso representam uma vantagem comparativa da COPPE.

João Ramos Torres, físico, introduz uma distinção importante: o impacto da IA é assimétrico entre áreas. Na matemática pura, processo formal, o impacto seria avassalador, já que modelos demonstram teoremas. Na física e na química, dependentes de laboratório, a IA não substitui a coleta de dados nem o planejamento experimental. Ilustra a mudança de prática com o contraste entre a estante de manuais do MicroVAX e a ausência atual de manuais, e relata a consequência pedagógica concreta de ter substituído as listas de exercícios de eletromagnetismo por resolução no quadro. Conclusão otimista, com precedente histórico: o elétron não teria sido descoberto sem a bomba de vácuo; ferramentas novas abrem horizontes.

4.2 Álvaro Coutinho — Aprendizado de máquina científico

Ideia central. Aprendizado de máquina científico não é caixa-preta, e a prova disso é metodológica: para cada barreira concreta da simulação de grande porte existe uma técnica específica cuja escolha se justifica matematicamente, e a pergunta decisiva não é a acurácia do método, mas sua escalabilidade para problemas reais.

A linha de raciocínio é construtiva, encadeando quatro barreiras. Começa com uma restrição teórica dura: em esquema monolítico multifísico, a complexidade assintótica ótima é N^(4/3), atingida apenas por multigrid, e qualquer outro arranjo piora esse teto. Como o engenheiro nunca faz uma simulação isolada — faz otimização, quantificação de incerteza, projeto, ou seja, N_Q consultas — reduzir o custo por consulta deixa de ser conveniência e se torna condição. Daqui nasce a função do SciML: treinar com

um subconjunto pequeno e inferir o restante, já que o tempo de inferência é muito menor que o de simulação.

A primeira barreira técnica aparece ao combinar redução modal com refinamento adaptativo de malha: se cada *snapshot* vive em um espaço diferente, não há como calcular a decomposição em valores singulares. A solução — projeção L2 em malha de referência, com teorema que estabelece as condições — é apresentada como ataque direto à barreira de complexidade, e rende redução a cerca de 150 graus de liberdade com aceleração de 230× para erro relativo da ordem de 10^{-3}.

A segunda barreira é o limite da linearidade. No caso Rayleigh–Bénard, com Ra = 10^6, são necessários 110 modos (metade dos dados) e, com Ra = 10^{10}, cerca de 190 — praticamente todos. O palestrante nomeia o fenômeno (largura de Kolmogorov) e extrai a consequência: sob alta turbulência, compressão linear não entrega nada, e só resta buscar subespaço não linear via *autoencoder* variacional. É nesse ponto que faz sua intervenção conceitual mais forte sobre explicabilidade: como nada se explica num espaço completamente não linear, constroem-se propriedades matemáticas no subespaço — posto completo, ortogonalidade, simetrias — e a explicabilidade em ciência passa a ser exatamente a pergunta sobre quais propriedades matemáticas se podem extrair da representação. O balanceamento dos termos da função de perda (ajuste aos dados versus ortogonalidade) é então tratado como problema de otimização multiobjetivo, em contraste com o *annealing* usual na comunidade de computação.

A terceira barreira é aprender famílias de soluções em vez de uma: muda a condição de contorno, muda a geometria. Aqui invoca o teorema de aproximação universal de operadores e os dois operadores neurais dominantes. O episódio mais ilustrativo da palestra: um FNO de prateleira não caber na memória de uma GPU de 94 GB com lote 1. As duas saídas são comprar mais GPU ou ser mais esperto; optaram pela segunda, redistribuindo as dimensões espaciais no *branch* e a temporal no *trunk* ao estilo DeepONet, quebrando a estrutura tensorial e passando a usar 40% da memória no mesmo caso. Nota física relevante: a soma das saturações resulta 1 sem ter sido imposta.

A quarta barreira é humana, não computacional: montar e depurar à mão os arquivos XML de entrada do GEOS, com centenas de parâmetros cruzados, impede *workflows* com muitas consultas. A resposta são agentes que fazem mineração da literatura, geram as especificações, autocorrigem e submetem os jobs, com intervenção humana em pontos de decisão científica. Introduz aí uma observação de economia da pesquisa: até hoje o recurso computacional se contava em horas de supercomputador, e agora há também a contagem de *tokens*. Antecipando a pergunta sobre alucinação — também discutida na revisão por pares do artigo — relata três execuções independentes: variaram o estilo de execução e o número de rodadas de revisão, mas as decisões de modelagem convergiram para os mesmos conjuntos válidos.

Pontos críticos nas perguntas. Júlia questiona o que significa terceirizar a leitura da bibliografia para a IA. A resposta esclarece que não houve terceirização: o *prompt* pedia reproduzir dois artigos com um simulador diferente, as equações de estado foram calculadas por código pré-existente, e todos os pontos científicos foram validados por humano. O palestrante amplia a questão para um problema estrutural — o volume de artigos explode enquanto o tempo de revisão permanece o mesmo — e aponta quem é mais afetado: separar o que vale ler é mais simples para quem já tem experiência, e cada vez mais desafiador para pesquisadores juniores, o que transforma mentoria em questão aberta. Felipe pergunta sobre esquecimento no treino de agentes; a resposta distingue treino de agentes de treino do *surrogate*, descreve uma base de conhecimento anotada via MCP com verificações periódicas e uma

hierarquia de modelos que reserva os menos potentes para tarefas menos exigentes, por economia de *tokens*. Gustavo pergunta por que GNN e por que DMD padrão em vez de variantes; a resposta é que o tratamento proposto valeria para qualquer variante, já que o problema atacado era a incompatibilidade de espaços, e que malha não estruturada significa número arbitrário de vizinhos por ponto, o que o grafo representa naturalmente.

Conclusão do bloco. A agenda de pesquisa proposta é integração vertical: HPC e gerência de dados na base, métodos numéricos e simulação no meio, SciML acima, agentes orquestrando. O palestrante registra explicitamente que não há consenso metodológico no nível do SciML.

4.3 Henrique Pacheco — ML no *screening* de catalisadores

Ideia central. Para o experimentalista, machine learning é instrumento de decisão sobre qual experimento fazer em seguida, e o gargalo real não é o modelo, é a base de dados — do que decorre que a terceira geração do trabalho tenha de ser automatizar a própria construção da base.

O palestrante declara a intenção de fazer um contraste com a palestra anterior, que destaca pelo altíssimo nível computacional, trazendo a perspectiva do experimentalista, e de mostrar que essas ferramentas são acessíveis a quem trabalha em bancada, insistindo que a arquitetura é extrapolável para membranas, termodinâmica aplicada, controle de poluição. Organiza a exposição cronologicamente em três estágios.

O primeiro estágio parte da economia do laboratório. O exemplo do frasco de 10 mL de solução de rutênio a 1,5% custando cerca de R$ 7.000 oito ou nove anos atrás serve para mostrar que *screening* experimental de metais nobres é inviável em dinheiro e em tempo, e para justificar o lema do trabalho: fazer o experimento sem fazer o experimento, lendo o histórico. O CATS cobre três reações clássicas (deslocamento gás-água, oxidação seletiva de CO, reforma a vapor do metano), com cerca de 80 artigos cada e ~15 mil linhas, saída única em conversão, e redes neurais superando árvores de decisão e outras abordagens testadas. A base de dados desse estudo foi gentilmente cedida por colegas de um grupo da Turquia, que já haviam compilado os dados da literatura; o trabalho do laboratório concentrou-se no desenvolvimento do software. A análise de sensibilidade devolve a temperatura como *feature* dominante na reforma, resultado que ele mesmo qualifica de óbvio — e aqui está o movimento argumentativo fino: o valor não está em descobrir o óbvio, mas em recuperar quantitativamente a intuição química qualitativa e medir quanto a temperatura pesa em relação às demais variáveis. Dois problemas estruturais da literatura são nomeados: a reprodutibilidade (nem sempre todos os detalhes experimentais estão disponíveis) e a ausência de vocabulário comum, para a qual usa o termo técnico ontologia — cada grupo define seletividade de modo distinto, e fazer isso comparável é um problema.

O segundo estágio é o caso aplicado da despolimerização redutiva catalítica de lignina, com o INT. A lignina é apresentada como possivelmente a maior fonte renovável de carbono aromático, recalcitrante, hoje majoritariamente queimada. A base teve de ser construída à mão: 120 artigos de cerca de 20 anos, 722 experimentos, 20 a 65 variáveis, muitas categóricas (tipo de suporte: zeólita, óxido básico, hidroxiapatita, heteropoliácido), com otimização bayesiana de hiperparâmetros via Optuna. O R^2 caiu de cerca de 0,9 para 0,5–0,6, e a explicação é diagnóstica: os dados se aglomeram abaixo de 30% de rendimento, onde a tecnologia esbarra, e a região de alto rendimento — justamente a de interesse tecnológico — é esparsa e exige verificação cuidadosa. O palestrante pondera que descartar esses pontos não seria adequado, pois é justamente ali que está o interesse tecnológico.

O resultado que organiza a palestra vem da análise de sensibilidade: em três dos quatro modelos, a presença de solvente polar aprótico pesa mais que o metal primário, bem acima dele. O palestrante marca o quanto isso é heterodoxo para a catálise e adota a consequência prática: o projeto pausou a triagem de metais e passou a sondar solventes, começando a romper a barreira dos 30%. Observação lateral de método, feita antes de qualquer modelo: o níquel é o metal mais recorrente na literatura, mas não o de melhor desempenho médio — e isso vem de estatística descritiva, não de machine learning.

O terceiro estágio converge com o final da palestra anterior: usar LLMs como leitoras automáticas de PDF. O diagnóstico técnico é preciso — um artigo traz a informação em texto, tabela ou figura, e nenhum modelo faz bem as três tarefas ao mesmo tempo, o que exige um agente por tarefa. Já funcionam os agentes de identidade do catalisador, de metal–suporte e de normalização ontológica, que reconhece que *layered double oxide* e *mixed oxide* de MgAl designam o mesmo material. Condições de operação e resultados, que exigem triangular texto, tabela e figura, ainda estão em desenvolvimento. Nas métricas de extração obtidas pelo grupo, Claude teve desempenho um pouco superior ao ChatGPT, e o Gemini teve desempenho inferior nessa tarefa específica; alucinação e omissão aparecem como falso positivo e falso negativo, e permanece necessária ao menos uma etapa de checagem humana.

Pontos críticos nas perguntas. Miguel pergunta se a IA consegue descer da identificação do metal às propriedades da síntese; a resposta é sim, com um alerta técnico: técnica de preparo não é variável fenomenológica, e desdobrá-la gera correlação excessiva entre entradas, o que reduz variabilidade útil. Juan pergunta sobre a normalização, que o palestrante confirma ter sido inteiramente manual, e levanta o condicionamento da biomassa; a resposta esclarece que granulometria e tipo de lignina estavam entre as 68 variáveis, mas que nem todo artigo as reporta, o que devolve o problema da esparsidade e exige decisão caso a caso. Igor pergunta pelo problema inverso — dada a conversão, obter a composição — e a resposta aponta uma dificuldade estrutural, já que o mapa não é injetivo: composições distintas dão conversões parecidas, com sobreposição de respostas, e possíveis contornos seriam clusterização prévia ou análise de componentes principais. Em resposta a Igor, o palestrante registra também um dado institucional relevante: as assinaturas de IA usadas no trabalho não têm custeio institucional, porque esse tipo de gasto ainda é recente demais para ter rubrica própria em projetos. Ana levanta a questão da confiabilidade dos dados publicados; a resposta reconhece que dados publicados podem conter inconsistências, indica o teste de Hotelling para detectar *outliers* e formula o dilema de modo elegante: toda tecnologia disruptiva é, por definição, um *outlier*, de modo que automatizar o descarte estatístico pode eliminar o próprio *breakthrough*. Maurício encerra com um registro histórico: redes neurais já eram usadas no início dos anos 1990, em colaboração com Vera Salim, do NUCAT, em tese defendida em 1993, relacionando condições de preparo às características finais do catalisador.

Conclusão do bloco. Quatro mensagens finais: *garbage in, garbage out*; heterogeneidade e esparsidade importam; padrões ficam escondidos em muitos dados e o computador os revela; o computador sugere, o pesquisador decide — formulação reforçada da plateia por Álvaro Coutinho, para quem o crédito é do pesquisador, não do computador, e que atravessa o dia.

4.4 Amanda Lemette — Diagnóstico de falhas e modelagem híbrida

Ideia central. São dois regimes opostos de dados, e cada um pede uma resposta diferente: com muitos dados, vale aprofundar um único modelo em vez de comparar muitos; com poucos dados, o conhecimento fenomenológico entra na função de perda e substitui os dados que faltam.

A primeira metade parte da segurança de processo. Bhopal (1984) abre a palestra, e a tese sobre falhas é que acidente não ocorre do nada: é efeito dominó, que começa numa falha controlada mas não corrigida na causa, e cujo perigo maior é passar a ser tratada como parte da rotina. Distingue com clareza detecção (há algo errado?) de diagnóstico (o que está errado e por quê?), e observa que o desafio contemporâneo não é falta de dados de planta, mas extrair informação deles a tempo — antes que a falha comprometa a especificação do lote.

O trabalho usa o *benchmark* Tennessee Eastman: 52 variáveis de processo, 20 falhas, cerca de 5 milhões de pontos, séries temporais. A escolha metodológica é o ponto interessante. Em vez de propor um modelo novo ou comparar vários, tomaram um modelo convolucional já publicado e com bons resultados e investigaram até onde ele poderia ser aprimorado. Séries temporais são convertidas em imagens por GASF — reescala para [-1, 1], passagem a coordenadas polares e matriz que guarda, em cada célula (i, j), o cosseno da soma dos ângulos nos instantes i e j — produzindo algo legível como mapa de calor. Quatro frentes foram testadas: enriquecer as imagens de entrada por rotação e empilhamento, mexer em filtros e *kernel* apenas na primeira camada, combinar as duas, e aumentar a capacidade nas camadas seguintes. O resultado é instrutivo porque inclui também o que não trouxe ganho: enriquecer as imagens não ajudou nem piorou; o que melhorou foi capacidade — mais filtros na primeira camada e nas subsequentes, e *kernel* maior, que amplia a vizinhança observada — e mesmo esse ganho encontrou um limite. Chegaram a cerca de 90% de diagnóstico correto, superando a referência. As falhas que permanecem confundidas têm explicação física: a 3 e a 9 afetam a mesma variável, temperatura de alimentação, uma como degrau e outra como perturbação aleatória.

A segunda metade inverte o cenário: no laboratório não há base ampla, por mão de obra e custo de reagentes e caracterizações. A formulação que organiza esta parte é que os dados dão o nível e a teoria dá a forma. A rede apresentada é a PCINN, que a palestrante distingue explicitamente da PINN. Sua função de perda soma dois termos: o ajuste aos dados experimentais, erro quadrático médio entre a predição da rede e as observações; e uma restrição física, que compara, nos pontos de colocação, a derivada da predição da rede em relação à entrada, obtida por diferenciação automática, com a derivada teórica prevista pelo modelo físico, calculada de forma independente do treinamento. A rede aprende os valores observados e é penalizada quando suas derivadas diferem das previstas pelo modelo. Na exposição oral, a palestrante descreveu também uma rede auxiliar ("rede física" ou "teórica") treinada com dados simulados pelo modelo fenomenológico — no primeiro estudo de caso, 10 mil reações simuladas com 250 pontos no tempo cada. A distinção com a PINN é o argumento central e está inteira no segundo termo da perda: na PINN, a derivada da rede é comparada ao lado direito da equação do modelo, f(ŷ, t), avaliado sobre a própria predição da rede, o que impõe a equação como restrição rígida — e um modelo fenomenológico pouco representativo compromete o resultado. Na PCINN, a referência é a derivada do modelo físico, independente da rede: a física orienta a direção sem prender a rede, e os dados corrigem onde o modelo erra.

As duas funções de perda, como apresentadas nos slides da palestra:

```
L_{PCINN} = \frac{1}{n_{exp}} \sum_{i=1}^{n_{exp}} \left( \hat{y}(x_i) - y_i^{exp}
\right)^2 + \frac{1}{n_{teo}} \sum_{j=1}^{n_{teo}} \left( \left. \frac{d\hat{y}(x_j)}
{dt} \right|_{rede} - \left. \frac{dy(x_j)}{dt} \right|_{teoria} \right)^2
```

```
L_{PINN} = \frac{1}{n_{exp}} \sum_{i=1}^{n_{exp}} \left( \hat{y}(x_i) - y_i^{exp} \right)^2 + \frac{1}{n_{teo}} \sum_{j=1}^{n_{teo}} \left( \left. \frac{d\hat{y}(x_j)}{dt} \right|_{rede} - \left. f(\hat{y}, t) \right|_{rede} \right)^2
```

O primeiro termo é idêntico nas duas. No segundo, a PCINN usa a derivada calculada pela teoria; a PINN usa o modelo avaliado sobre a saída da própria rede.

Dois casos sustentam a tese. No de Letícia, dados da copolimerização de etileno com decadieno gerados no doutorado da palestrante: 14 experimentos, apenas sete grupos independentes (G e H compartilham condição experimental, variando só o tempo), com validação cruzada adotada tanto pela escassez quanto pela suspeita de vazamento de dados. O modelo original, segundo a própria palestrante, tinha incertezas reconhecidas — mecanismo cinético simplificado, constantes em parte estimadas e em parte obtidas da literatura, e hipóteses sem plena confirmação — e a PCINN superou tanto a MLP pura quanto o modelo cinético em MAPE para massas molares médias. No de Alexandre, polimerização em suspensão de PBS com dados de uma *startup*: o modelo adaptado do PEF limitava a dispersividade a 2, porque o mecanismo assumia igual probabilidade de reação independentemente do tamanho das cadeias, e corrigir isso exigiria complexidade sem graus de liberdade para estimar os parâmetros extras. Duas penalidades foram acrescentadas à perda: monotonicidade, porque massa de condensado acumulada não pode diminuir no tempo, e dispersividade, penalizando MW menor que MN — ambas restrições de consistência física, não ajustes estatísticos. A PCINN acompanhou os dados em casos com dispersividade de 1,73 a cerca de 3,4, inclusive onde o modelo representava bem MN, mas não MW.

Pontos críticos nas perguntas. A primeira pergunta, sobre custo computacional, extrai um contraste expressivo: a CNN exigiu boa GPU e cerca de 5 horas de treino (antes da troca de máquina, levava dois dias), enquanto a PCINN treina em tempo próximo de zero. A segunda pergunta propõe combinar PINN e PCINN por região de confiança — a restrição rígida da PINN onde o modelo fenomenológico é confiável, a da PCINN onde não é, eventualmente por variável — e a resposta reconhece que ninguém fez isso ainda e que é oportunidade de investigação, ressalvando o custo de sintonizar as regiões. A terceira, de um participante, é de natureza mais conceitual: até onde se deve investir na modelagem física antes de abandoná-la em favor dos dados? A palestrante reconhece que a questão segue em aberto e relata o experimento que a motiva — tentaram se uma PCINN guiada por um modelo de etileno puro aprenderia o comportamento da copolimerização a partir dos dados, e não aprendeu, restando indeterminado se foi por insuficiência de dados ou por limite do método. O mesmo participante sugere ainda uma alternativa: uma rede estimando a variação da taxa com o tamanho de cadeia seria outra forma de modelo híbrido.

Conclusão do bloco. Muitas vezes é possível ir além aprofundando um mesmo modelo, em vez de substituí-lo logo após a primeira otimização de hiperparâmetros. E o modelo fenomenológico não precisa estar certo em tudo, precisa dar a forma — corolário prático: se o modelo já está muito bem validado, a PCINN pouco se diferencia da PINN; sua vantagem aparece quando o modelo ainda pode ser melhorado.

4.5 Rafael Mesquita — IA na engenharia de enzimas

Ideia central. O que o artigo e o software não entregam é justamente o que decide o uso: erro, precisão e faixa de confiança têm de ser medidos pelo próprio usuário, com controles positivos e negativos, e o papel legítimo dessas ferramentas é triar, formando um funil que leva menos coisa à bancada.

O palestrante se posiciona desde o início como usuário e não desenvolvedor — sabe distinguir para que serve, para que não serve e quais são os "quebra-molas". Começa definindo a IA como software treinado, e introduz, além das LLMs, um tipo que atribui probabilidades a alternativas de múltipla escolha, muito mais rápido, destinado a roteamento automático por software.

A ponte para a biologia são os modelos de linguagem de proteínas: mesma arquitetura das LLMs, com sequências de aminoácidos no lugar de texto, treinados sobre dezenas de milhões de *clusters* de sequências. A explicação de *embedding* é feita por analogia: um formulário com milhares de itens para julgar se alguém está elegante, em que cada unidade de informação é uma dimensão e o todo só significa em conjunto. A revelação pessoal que acompanha isso é metodologicamente importante: ele tentava inicialmente numerificar e fornecer características físico-químicas — polaridade, raio atômico, eletronegatividade, pontes de hidrogênio — até perceber que o modelo as deduz das sequências. Ponto conceitual decisivo: um PLM não é uma IA final, é o primeiro bloco que gera a representação matemática usada por uma segunda IA, e entra congelado. Observação prática recorrente: o número de parâmetros determina a memória de GPU, não a RAM — cerca de 0,6 GB roda em qualquer laptop, cerca de 30 GB exige placa profissional.

A primeira dimensão é pH ótimo. O modelo adotado inicialmente usa internamente a versão 1 do ESM, treinado com cerca de 9 mil enzimas com pH ótimo conhecido e refinado com cerca de 2,2 milhões de sequências por uma inferência engenhosa: se uma bactéria vive bem em certo pH ambiental, as enzimas que ela secreta devem funcionar razoavelmente nesse pH — extraídas por bioinformática a partir de peptídeo sinal de secreção. Ele explica por que o refinamento é necessário (9 mil sequências seriam insuficientes para o treinamento; dariam no máximo uma matriz de pesos por posição, que chama de avô da IA) e identifica o viés imediatamente: a massa dos dados vem de pH em torno de 7. A analogia é didática — quem treina 10 horas de basquete e 2 de natação se sai melhor no basquete. A tentativa própria de trocar ESM1 por ESM3 teve resultado misto, e ele mostra os dois lados: ganho no neutro, nenhuma melhora no ácido, erro total em pH 10. O grupo encerrou essa linha — inclusive a ampliação planejada do conjunto de 9 mil para cerca de 30 mil enzimas — quando surgiu uma IA com melhor desempenho — "paramos de reinventar a roda" — mas com uma consciência precisa da limitação: a nova ferramenta parte do princípio de que sequências muito similares compartilham pH ótimo, o que é incompatível com o objetivo original de avaliar efeito de mutação de um único aminoácido. A medição própria de faixa de erro mostra acerto razoável em ±0,5 unidade de pH e queda abrupta se a tolerância cai para ±0,1 — e ele destaca que essa faixa de confiança precisou ser estimada pelo próprio grupo, já que o software devolve um valor pontual.

A segunda dimensão é termoestabilidade. A ferramenta usada gera internamente, por força bruta, todos os mutantes simples possíveis em todas as posições e calcula ΔΔG contra a sequência original. Comparada ao Rosetta, a diagonal é mais larga, ou seja, menos precisa; mas a diferença de tempo é de dias por mutação contra minutos para todas, o que a torna aproveitável como filtro de larga escala mesmo não servindo para cravar valores. Reconhece explicitamente que haverá falsos negativos e falsos positivos na cauda que interessa.

A terceira dimensão é afinidade com substratos, via Boltz-2, ainda em *pre-print*. Recebe sequência de aminoácidos e SMILES do ligante, faz simultaneamente modelagem tridimensional e cálculo de afinidade, com código e pesos abertos, precisão comparável à de *free energy perturbation* e cerca de mil vezes mais rápido. A estrutura da exposição é deliberadamente invertida: quatro trechos elogiosos —

bom desempenho em *benchmarks* de estrutura, melhor resultado numa edição do CASP, posicionamento adequado do ligante, treino com cerca de 2,5 milhões de ligantes — seguidos da ressalva que reorganiza tudo: precisão média de 0,025, muitos falsos positivos e negativos, dificuldade de distinguir *hits* de *decoys*. Daí a regra: não se usa a ferramenta às cegas para qualquer proteína, é preciso um controle por proteína.

A validação própria é o melhor exemplo do método defendido. Controle positivo: substratos reconhecidamente ligados, verificados visualmente quanto ao posicionamento (parte catalisada para dentro), e reprodução do comportamento conhecido de afinidade crescente com o tamanho da cadeia carbônica — tendência global correta, sem pretensão de que o número seja ΔG. Controle negativo: enzima muito semelhante em sequência e estrutura, mas sem aquela atividade catalítica, para a qual o ligante caiu fora do sítio e as afinidades deram todas desfavoráveis. Ele acrescenta a estatística honesta de generalização: em três casos de uso, funcionou em dois; no terceiro, os controles não foram reproduzidos.

Pontos críticos nas perguntas. O mediador pergunta se serve para anticorpos (sim, com desempenho razoável nos *benchmarks*) e sobre hardware (placa de vídeo de nível *gamer*, no mínimo). Júlia pergunta: chegando ao palpite, qual o próximo passo para bater o martelo? A resposta descreve o funil completo — descartar o número de afinidade e aproveitar a pose, calcular MM-PBSA, depois dinâmica molecular em caixa com água, descartando o início e extraindo a afinidade após o equilíbrio dinâmico — com a justificativa econômica da triação: a dinâmica de um anticorpo pode levar de uma semana a um mês na melhor placa disponível, e por isso não se pode submeter tudo a ela. Um participante aponta um limite estrutural: as interações dependem de condições físico-químicas, mas o treino usa só sequência, e não há como informar pH, temperatura ou concentração salina. A resposta confirma e explica a causa raiz — seria preciso um conjunto de treino em que cada medida de afinidade viesse acompanhada do pH e da temperatura em que foi medida — e relata que essas informações estão atualmente perdidas no espaço de *embeddings*, mencionando um grupo que desenvolve método para isolar os *embeddings* correlacionados a características físico-químicas específicas. A última pergunta estabelece a analogia com *autoencoders* e pergunta pela engenharia reversa: é possível reconstruir a proteína a partir dos *embeddings*? A resposta é que provavelmente não, porque o modelo não foi desenhado para preservar a informação necessária à decodificação — retomada pela analogia: tabularam-se os formulários e descartaram-se os individuais.

Conclusão do bloco. Três regras de uso: avaliar erro e precisão da IA com o próprio conjunto de teste, porque isso não vem no artigo nem no software; fazer controles negativos e positivos como se fazem na bancada, submetendo até entradas sem sentido para ver o que volta; e não tratar nenhum resultado como verdade absoluta — na melhor hipótese, um palpite.

5. Glossário de conceitos de IA e Machine Learning

Todos os conceitos abaixo foram efetivamente discutidos no áudio. A coluna de aplicação registra o problema concreto a que cada um foi associado pelo palestrante, não o uso genérico da técnica.

5.1 Fundamentos e arquiteturas

Conceito	Definição apresentada	Aplicação no colóquio
Aprendizado de máquina científico (SciML)	Subconjunto da IA em que a lei física, ou um modelo matemático de equações diferenciais, entra na formulação. Distingue-se de IA genérica porque o resultado precisa satisfazer as hipóteses do modelo (p. ex., divergência nula para escoamento incompressível)	Moldura geral do keynote
Modelo substitutivo (*surrogate*, emulador)	Modelo treinado com dados gerados por simulação de alta fidelidade, que substitui a simulação nas consultas restantes porque o tempo de inferência é muito menor	Otimização, quantificação de incerteza e projeto
Rede neural (MLP)	Camadas ocultas e funções de ativação mapeando entradas em saídas; teorema da aproximação universal garante aproximar qualquer função	*Screening* de catalisadores (melhor desempenho médio entre as alternativas testadas); base de comparação para a PCINN
Rede neural convolucional (CNN)	Rede que recebe imagens; filtros e dimensão do *kernel* controlam capacidade e tamanho da vizinhança lida	Diagnóstico de falhas no Tennessee Eastman
Autoencoder e espaço latente	Busca de um sistema de coordenadas reduzido não linear que ainda represente a dinâmica	140 mil graus de liberdade reduzidos a 16 no problema de turbiditos
Autoencoder variacional (VAE)	Perda com termo de representação dos dados e termo estatístico que informa o acoplamento dos modos	Rayleigh–Bénard, onde a redução linear falha
Rede neural em grafo (GNN)	Cada ponto do espaço tem número arbitrário de vizinhos; o grafo representa isso naturalmente e promove *embedding* da informação irregular	Malhas não estruturadas de reservatório; mencionada também para estruturas moleculares
LSTM	Usada no espaço latente após o *embedding* do grafo	Sequência temporal em malha não estruturada
Transformer	Arquitetura comum a LLMs e modelos de linguagem de proteínas	Mencionada como base do ESM

5.2 Operadores neurais e redução de ordem

Conceito	Definição apresentada	Aplicação no colóquio
Teorema de aproximação universal de operadores	Enquadramento matemático para aprender não uma solução, mas a aplicação que leva do espaço das funções de entrada ao das de saída — famílias de soluções	Justificativa para operadores neurais quando mudam geometria ou condições de contorno
Operador neural de Fourier (FNO)	*Kernel* de convolução espectral, com ida e volta ao espaço de Fourier por FFT; limitado a malhas estruturadas	Simulação de reservatório 2D; estourou a memória de GPU de 94 GB
DeepONet (*branch* e *trunk*)	Duas redes cujas saídas se combinam como expansão em base; o *branch* mapeia a entrada discretizada, o *trunk* define onde se quer a resposta	Arquitetura híbrida que quebrou a estrutura tensorial do FNO e reduziu a pegada de memória a 40%
Decomposição em modos dinâmicos (DMD)	Método linear de análise modal que relaciona o estado posterior ao anterior minimizando a norma de Frobenius	Correntes de turbidez; autovalores para a resposta dinâmica
Decomposição em valores singulares (SVD/POD)	Base da redução linear; a pseudo-inversa é mal condicionada e se escolhem R modos	Primeiro estágio das reduções em dois passos
Largura (comprimento) de Kolmogorov	Mede a capacidade de uma representação linear de comprimir os dados; sob alta turbulência, a compressão linear deixa de compensar	Diagnóstico quantitativo: 110 modos para Ra = 10^6, ~190 para Ra = 10^{10}
Projeção L2 em malha de referência	Contorna o fato de que *snapshots* de malhas adaptativas não vivem no mesmo espaço, com teorema de condições; já disponível em pacotes de volumes e elementos finitos	Habilita redução modal com refinamento adaptativo
PINN (*physics-informed neural network*)	Pontos de colocação onde se minimiza o resíduo para impor a física: a derivada da rede é comparada a f(ŷ, t) avaliado sobre a própria predição. Restrição física rígida	Citada nas duas palestras; contraponto à PCINN
PCINN	Perda com termo de ajuste aos dados mais termo de restrição física, que compara nos pontos de colocação a derivada da predição da rede (por diferenciação automática) com a derivada teórica do modelo fenomenológico, calculada independentemente do treinamento. A física	Copolimerização etileno–decadieno; polimerização de PBS

Conceito	Definição apresentada	Aplicação no colóquio
	orienta a direção sem prender a rede	
Modelos de linguagem de proteínas (PLM/ESM)	Mesma arquitetura das LLMs, com sequências de aminoácidos no lugar de texto; não são IA final, geram a representação usada por uma segunda IA e entram congelados	Primeiro bloco dos preditores de pH, estabilidade e afinidade
Embedding	Vetor de milhares de dimensões, um por resíduo e um para a proteína inteira, que codifica características físico-químicas sem que elas tenham sido fornecidas; *embeddings* próximos indicam semelhança	Entrada numérica dos modelos a jusante; pH e temperatura ficam "perdidos" nesse espaço

5.3 Treinamento, métricas e diagnóstico

Conceito	Definição apresentada	Aplicação no colóquio
Otimização multiobjetivo da *loss*	Tratar o balanceamento dos termos da função de perda como problema multiobjetivo, em vez do *annealing* usual	Compromisso entre ajuste aos dados e ortogonalidade no VAE
Termos de penalidade por consistência física	Penalidades acrescentadas à perda quando a predição viola o que não pode ocorrer	Monotonicidade da massa de condensado e MW não menor que MN no PBS
Otimização bayesiana de hiperparâmetros	Busca automatizada de hiperparâmetros (ferramenta citada: Optuna)	Modelos da despolimerização de lignina
Validação cruzada	Rotação do conjunto de teste quando há poucos experimentos	Sete grupos experimentais na copolimerização
Vazamento de dados	Experimentos quase idênticos no treino e no teste equivalem a entregar a resposta à rede	Experimentos G e H, de mesma condição experimental
Análise de sensibilidade e importância de *features*	Ordenação quantitativa das variáveis de entrada por impacto na saída	Temperatura na reforma; solvente aprótico acima do metal na lignina
Explicabilidade	Em ciência, equivale a perguntar quais propriedades matemáticas se podem extrair da representação (ortogonalidade, posto completo, simetrias)	Construção do subespaço no VAE

Conceito	Definição apresentada	Aplicação no colóquio
Esparsidade e heterogeneidade dos dados	Dados concentrados numa região e escassos fora dela degradam a predição justamente onde interessa	*Cluster* abaixo de 30% de rendimento na lignina
Ontologia	Fazer humanos e máquinas usarem a mesma língua quando termos diferentes designam a mesma coisa	Definições divergentes de seletividade; normalização de nomes de materiais
Variáveis categóricas	Exigem estratégia de quantificação e elevam a complexidade numérica da matriz de entrada	Tipo de suporte catalítico
Alucinação e omissão	Falso positivo e falso negativo na extração: afirmar o que não existe e deixar passar o que existe	Métricas de extração por LLM a partir de PDFs
Guardrails	Restrições impostas ao comportamento da LLM; úteis, mas sem garantia — se não funcionarem, fica-se no mesmo ponto em que se estava antes	Levantados por Felipe em pergunta
GASF (*Gramian Angular Summation Field*)	Transforma série temporal em imagem: reescala a [-1, 1], passa a coordenadas polares e guarda em cada célula (i, j) o cosseno da soma dos ângulos	Alimentação da CNN com 52 variáveis de processo
Detecção versus diagnóstico	Detecção responde se há algo errado; diagnóstico responde o que está errado e por quê, classificando a falha	Enquadramento do trabalho sobre Tennessee Eastman
Aprendizado não supervisionado e clusterização	Sugerido para agrupar respostas próximas antes de atacar um problema mal-posto	Proposta para o problema inverso do CATS
Análise de componentes principais	Sugerida para descorrelacionar entradas redundantes	Correlação excessiva entre descritores de catalisador
Hits e *decoys*	*Decoy* é molécula de peso e funções químicas semelhantes, distribuídas de outro modo; serve de controle negativo	Treinamento do módulo de afinidade (~2,5 milhões de ligantes)
Precisão e amplitude de erro medidas pelo usuário	Faixa de confiança e taxa de acerto que o artigo e o software não informam e que o usuário precisa estimar com o conjunto de teste	±0,5 unidade de pH; precisão média de 0,025 na afinidade
Viés do conjunto de treino	Se a massa dos dados vem de uma faixa, a saída herda a tendência	Predominância de pH próximo de 7 no treino

5.4 Agentes, LLMs e infraestrutura

Conceito	Definição apresentada	Aplicação no colóquio
LLM	Software treinado com grande volume de texto que devolve a sequência de maior probabilidade; mudar a palavra-chave de entrada muda a saída	Leitura de literatura; extração de dados de artigos
Agentes de IA e especialização por tarefa	Nenhum modelo faz bem, ao mesmo tempo, ler texto, tabela e figura; daí um agente por tarefa, com etapa de normalização	Geração de *decks* XML do GEOS; construção de base de dados a partir de PDFs
Autocorreção e portas de decisão humana	O agente corrige os próprios erros, mas pontos de decisão científica ficam com o humano	Escolha de modelo, profundidade e equações de estado no fluxo do GEOS
Base de conhecimento e proveniência	Registro das interações, via MCP e *skills*, para evitar repetição de erro; banco de proveniência consultável	Resposta à pergunta sobre esquecimento no treino de agentes
Hierarquia de modelos	Modelo menos potente para tarefas menos exigentes, por economia de *tokens*	Mesma resposta
Tokens como recurso de pesquisa	Nova unidade de custo computacional, ao lado das horas de supercomputador; 343 mil *tokens* em uma rodada	Observação de economia da pesquisa; assinaturas de IA ainda sem rubrica institucional
Reprodutibilidade de agentes	Execuções independentes em que variaram estilo e número de rodadas de revisão, mas convergiram as decisões de modelagem	Resposta antecipada à objeção de alucinação
Modelo probabilístico por alternativas	Treinado com contextos textuais e recompensas programáticas, devolve probabilidade de cada alternativa; muito mais rápido que LLM	Roteamento automático de mensagens em software
Memória de GPU como limite prático	O que limita é a memória da placa, não a RAM; ~0,6 GB roda em laptop, ~30 GB exige placa profissional	Escolha do tamanho do modelo ESM; barreira de memória no FNO
HPC e computação paralela	Camada de base da pilha proposta; a pergunta de escalabilidade dos anos de CFD retorna idêntica no contexto de ML	Visão integrada do keynote

5.5 Ferramentas e bases de dados nomeadas

Nome	O que é	Como foi usada
CATS (*Catalyst Screener*)	Software próprio de seleção de catalisadores, de 2022	Três reações clássicas, ~15 mil linhas, $R^2 \approx 0,9$
GEOS	Simulador aberto (Lawrence Livermore, TotalEnergies, Stanford) cuja entrada são arquivos XML com centenas de parâmetros cruzados	Gerador de dados para o *surrogate*; alvo da automação por agentes
Tennessee Eastman	*Benchmark* teórico de planta química: 52 variáveis, 20 falhas, ~5 milhões de pontos	Diagnóstico de falhas
The Well	Conjunto de dados comunitário de referência	Estudo de Rayleigh–Bénard
Optuna	Biblioteca de otimização de hiperparâmetros	Modelos da lignina
TensorFlow e PyTorch	Ambientes de implementação que permitem adaptar o treinamento	Implementação da PCINN
ESM (e sucessores)	Família de modelos de linguagem de proteínas da Meta, de 8 milhões a bilhões de parâmetros	Geração de *embeddings*; tentativa de troca de versão dentro de um preditor de pH
UniRef50 / UniRef90	Conjuntos de *clusters* de sequências proteicas usados no treino	Entrada do ESM
Preditor de pH ótimo baseado em ESM	Treinado com ~9 mil enzimas e refinado com ~2,2 milhões de sequências por pH ambiental	Primeira dimensão da palestra de enzimas
BRENDA	Banco de dados de enzimas	Fonte majoritária dos pH ótimos
RaSP	Preditor de ΔΔG com mutação por força bruta de todos os mutantes simples	Triagem de termoestabilidade
Rosetta	Referência mais confiável para ΔΔG computacional, mas de dias por mutação	Comparação de precisão e de tempo
Boltz-2	Modelo aberto (MIT) que faz modelagem 3D e afinidade a partir de sequência e SMILES; ~1000× mais rápido que FEP	Triagem de interação enzima –substrato
FEP (*free energy perturbation*)	Método físico de referência para afinidade	Padrão de comparação
MM-PBSA e	Etapas seguintes do funil, de maior precisão e custo	Confirmação da pose vinda

Nome	O que é	Como foi usada
dinâmica molecular		do Boltz-2
CASP	Competição internacional de predição de estrutura com alvos não depositados	Evidência de desempenho em estrutura
SMILES	Representação unidimensional de uma molécula	Entrada do ligante

6. Padrões transversais e conclusões do dia

Os quatro palestrantes vêm de áreas distintas — mecânica computacional, catálise experimental, engenharia de sistemas de processos, bioquímica — e no entanto convergem em seis teses. A convergência é o achado mais forte da leitura integral: chegam ao mesmo lugar em parte por caminhos independentes e em parte em diálogo direto — Henrique Pacheco retoma explicitamente pontos do keynote, e Álvaro Coutinho intervém da plateia durante a palestra seguinte.

1. A decisão permanece humana, e isso é técnico, não retórico. A formulação — o computador sugere, quem decide é o pesquisador — aparece na palestra de Henrique Pacheco, reforçada da plateia por Álvaro Coutinho (o crédito é do pesquisador, não do computador), e reaparece na palestra de enzimas. O que impede que isso seja mera deferência é o fundamento dado em cada caso: no GEOS, porque a seleção de modelo e equações de estado exige validação científica em portas de decisão; na catálise, porque uma base contaminada produz conclusão alucinada a partir da qual o pesquisador fica "casado com uma verdade que não existe"; nas enzimas, porque na melhor hipótese o resultado é um palpite. A abertura antecipara o ponto na chave formativa: a base e o senso crítico são tão ou mais importantes do que sempre foram.

2. O gargalo migrou do modelo para os dados. Nenhum palestrante apresentou a arquitetura como dificuldade principal. A dificuldade é ter dados, e em quatro formas distintas: construí-los à mão lendo 120 artigos; ter acesso a dados industriais, o que levou à escolha de um *benchmark* aberto; gerar 14 experimentos de laboratório a custo de reagentes e caracterizações; dispor de apenas 9 mil enzimas com pH ótimo medido. As respostas são diferentes — agentes leitores de PDF, *benchmark* público, física na função de perda, inferência por pH ambiental — mas o problema é um só. A máxima *garbage in, garbage out* foi enunciada explicitamente numa palestra e opera como premissa nas outras três.

3. A caixa-preta é recusada, e a explicabilidade é redefinida. O keynote afirma que SciML não é caixa-preta e propõe uma definição operacional: explicabilidade em ciência é saber quais propriedades matemáticas se conseguem extrair da representação. A mesma recusa aparece transposta nas outras palestras — impor consistência física via penalidades na *loss*, ou exigir que o resultado reproduza o comportamento químico conhecido antes de ser aceito. Em todos os casos, confia-se no modelo por uma propriedade verificável, não por métrica agregada. Vale notar que a soma das saturações dar 1 sem ter sido imposta foi apresentada como evidência dessa ordem.

4. Escalabilidade pesa mais que acurácia. Explicitada no keynote — a pergunta não é só a precisão do método, é como escalá-lo para problemas reais — ela reaparece em cada palestra como escolha concreta: comprar GPU ou mudar arquitetura; triar com ferramenta imprecisa mas rápida e reservar a

dinâmica molecular para poucos candidatos; aceitar ΔΔG de qualidade inferior em minutos no lugar de dias por mutação; trocar de máquina para reduzir o treino de dois dias a cinco horas. Há uma regra implícita comum: uma ferramenta imprecisa é útil quando usada para descartar, não para afirmar.

5. O mérito está em aprofundar, não em trocar. Formulada diretamente por Amanda Lemette — pegar um modelo publicado e explorar o que os autores não exploraram, em vez de abandoná-lo quando a otimização de hiperparâmetros não entrega — a tese tem um contraponto honesto na palestra de enzimas, onde o julgamento foi oposto: diante de ferramenta melhor, pararam de reinventar a roda. Os dois casos não se contradizem; delimitam o critério. Aprofundar vale quando o limite é de exploração; abandonar vale quando o limite é de concepção.

6. Os efeitos sobre a formação foram tratados como problema aberto, não resolvido. É o único tema em que ninguém ofereceu solução. A abertura o coloca como pergunta central do colóquio — quais profissionais formar em 5, 10, 20 anos, com a ressalva de que talvez não se consiga prever tão longe. O keynote acrescenta um aspecto: separar o que vale ler é mais simples para quem já tem experiência e cada vez mais desafiador para o pesquisador júnior, o que torna a mentoria uma questão em aberto. A observação sobre catálise é paralela: um pesquisador experiente já sabe o caminho das pedras, e o pesquisador em início de carreira, que mais se beneficiaria da ferramenta, ainda está construindo o repertório necessário para avaliar seus resultados. A isso somam-se a decisão pedagógica relatada na abertura (substituir listas por resolução no quadro) e o diagnóstico de que a questão do ensino-aprendizagem segue em processo.

6.1 Conceitos que reaparecem em mais de uma palestra

Conceito	Onde reaparece	O que muda de uma para outra
Agentes de IA para montar bases de dados	Keynote (XML do GEOS) e Pacheco (PDFs de artigos)	O keynote parte de fonte estruturada; Pacheco enfrenta texto, tabela e figura, problema reconhecidamente mais duro, e ele mesmo marca a sobreposição
Explosão da literatura e revisão bibliográfica	Keynote e Pacheco	De problema de produtividade do revisor a problema de construção de dados
Ontologia e vocabulário incompatível	Pacheco (seletividade, nomes de materiais) e keynote (tradução de casos da literatura para o formato de entrada do GEOS)	Nomeado como conceito técnico (ontologia) por Pacheco
Incorporar física ao aprendizado	Keynote (PINN, verificação de hipóteses) e Lemette (PCINN e perdas de consistência física)	De verificação *a posteriori* a termo na função de perda
Esparsidade dos dados	Pacheco (rendimento acima de 30%) e Lemette (poucos experimentos)	Esparsidade dentro da base versus escassez absoluta

Conceito	Onde reaparece	O que muda de uma para outra
Problema inverso e multiplicidade de soluções	Pacheco (conversão → composição) e Mesquita (*embedding* → proteína)	Mesma obstrução formal em domínios distintos: informação perdida no sentido direto
Redução de dimensionalidade e espaço latente	Keynote (SVD, *autoencoder*, VAE) e Mesquita (*embeddings*, representação 2D)	A analogia foi explicitada na pergunta final, que aproximou ESM e *autoencoders*
Falso positivo e falso negativo	Pacheco (alucinação e omissão) e Mesquita (*hits* e *decoys*, ΔΔG)	Mesma estrutura de erro, do texto à bioinformática
Limitações de memória de GPU	Keynote e Mesquita	De obstáculo a vencer com arquitetura a critério de escolha de modelo
O computador sugere, o pesquisador decide	Keynote, Pacheco e Mesquita	Aparece também na abertura, como ênfase na base e no senso crítico

6.2 Observações finais sobre o material

Três pontos merecem atenção de quem for usar esta transcrição como fonte primária.

As sessões de perguntas concentram o conteúdo mais original do dia e somam cerca de 50 minutos dos 4h44 de fala. Várias informações aparecem só ali: o custo de treino comparado, a ausência de custeio institucional para assinaturas de IA, o histórico de redes neurais no NUCAT desde 1993 e o teste, ainda inconclusivo, de uma PCINN guiada por modelo de etileno puro aplicada à copolimerização.

Três questões ficaram declaradamente sem resposta e valem como agenda: até onde investir na modelagem fenomenológica antes de recorrer aos dados; como formar e orientar pesquisadores juniores quando o acesso à informação é imediato e a filtragem de qualidade não o é; e como incorporar condições físico-químicas (pH, temperatura) a modelos treinados apenas em sequência.

Para citação acadêmica, nomes, números e referências devem ser confirmados nos artigos originais ou nos slides. A legenda é automática e, além de corromper nomes próprios, não capturou nenhum dado exibido apenas em tela — valores lidos em voz alta foram preservados aqui, mas títulos de artigos, afiliações completas e a grafia exata de alguns métodos permanecem incertos.

7. Fontes

- Vídeo do evento — XXIII Colóquio de Engenharia Química PEQ/COPPE/UFRJ, 04/11/26 — https://www.youtube.com/watch?v=yboTkF-94Is (canal Auditorio COPPE; duração 7:07:05)
- Programação oficial do colóquio — https://coloquio.peq.coppe.ufrj.br/programacao
- Legendas automáticas em português do mesmo vídeo (SRT, extraídas via DownSub — https://downsub.com), cobrindo 00:02:45 a 06:58:25

Síntese elaborada a partir da transcrição automática; nomes, números e referências a artigos devem ser confirmados contra os slides ou as publicações originais antes de citação acadêmica.