XXIII Colóquio de Engenharia Química PEQ/COPPE/UFRJ (05/11/2026)

Todo o texto deste documento foi gerado pelo Claude, da Anthropic, a partir da legenda automática do YouTube extraída por meio do DownSub. Nomes, números e referências a artigos devem ser confirmados contra os slides ou as publicações originais antes de citação acadêmica.

Sumário

1. Apresentação e nota metodológica
    a. Identificação do evento e da fonte
    b. Verificação da duração do arquivo
    c. Limitações da legenda automática e critérios adotados
2. Estrutura do evento
    a. Programação prevista e programação realizada
    b. Quadro-resumo das palestras
3. Índice cronológico por blocos de tempo
4. Eixo temático 1 — Automação e Gêmeos Digitais (manhã)
    a. Abertura do eixo: modelo digital, sombra digital e gêmeo digital
    b. Palestra — Thiago Anzai (PETROBRAS)
    c. Palestra — Thiago Feital (OPTIMATECH)
    d. Keynote — Thiago Oliveira (AVEVA)
    e. Síntese do eixo
5. Eixo temático 2 — Modelagem Híbrida (tarde)
    a. Keynote — Idelfonso Nogueira (NTNU)
    b. Palestra — Fabio Santos (LNCC)
    c. Palestra — Americo Cunha (LNCC)
    d. Síntese do eixo e encerramento do dia
6. Glossário de conceitos de IA e Machine Learning discutidos
    a. Conceitos gerais e aprendizado de máquina clássico
    b. IA generativa e modelos de linguagem
    c. Modelagem híbrida e IA informada pelo domínio
    d. Aprendizado de máquina científico (SciML)
7. Padrões, conceitos recorrentes e conclusões transversais
8. Principais assuntos discutidos
9. Considerações finais
10. Fontes

1. Apresentação e nota metodológica

O arquivo analisado registra o terceiro dia do XXIII Colóquio de Engenharia Química do PEQ/COPPE/UFRJ, realizado em 5 de novembro de 2026. O dia reuniu seis palestras em dois eixos temáticos: Automação e Gêmeos Digitais (manhã) e Modelagem Híbrida (tarde).

1.1 Identificação do evento e da fonte

A fonte única desta análise é a legenda automática em português do vídeo publicado no YouTube, baixada em formato SRT pelo serviço DownSub. O nome do arquivo identifica o evento como "XXIII Colóquio de Engenharia Química – PEQ/COPPE/UFRJ – 05/11/26". A sessão ocorreu no auditório da COPPE (sala G-122, segundo o moderador da tarde) e foi transmitida pelo canal do auditório. A página do vídeo no YouTube não pôde ser aberta durante a elaboração deste documento; por isso, título, canal e descrição oficiais do vídeo não foram conferidos.

A moderação da manhã coube ao Prof. Argemiro e a da tarde ao Prof. Maurício, ambos do PEQ/COPPE, conforme os nomes pronunciados na gravação.

1.2 Verificação da duração do arquivo

O arquivo confirma um registro de mais de 8 horas. Ele não contém, porém, uma única palestra: trata-se de um dia inteiro de colóquio, com seis palestras, sessões de perguntas e três intervalos.

Indicador	Valor medido no SRT
Primeiro carimbo de tempo	0:00:00
Último carimbo de tempo	8:30:46
Número de legendas (entradas SRT)	9.492
Linhas do arquivo	37.966
Palavras transcritas (aprox.)	58.900
Tempo sem legenda (intervalos superiores a 1 min)	cerca de 1 h 40 min
Tempo com fala legendada	cerca de 6 h 50 min

Os quatro trechos sem legenda correspondem ao coffee break da manhã (1:15 a 1:31), ao almoço (3:39 a 4:32), a ajustes de conexão para a palestra remota (4:38 a 4:44) e ao coffee break da tarde (6:48 a 7:13). Isso é coerente com a informação de que os intervalos ocorreram fora do auditório.

A gravação começa no meio de uma frase do moderador, já na introdução conceitual do eixo da manhã. Portanto, uma eventual fala de abertura deste dia, se ocorreu, não está no arquivo. O último bloco é o encerramento do terceiro dia, com convite para as atividades do dia seguinte.

1.3 Limitações da legenda automática e critérios adotados

- **Grafia de nomes e termos técnicos.** A legenda automática pode alterar a grafia de nomes próprios e termos em inglês (por exemplo, "Alfonso" ou "Idonso" para Idelfonso; "traction" para a empresa Tractian; "por fim" para a família de modelos PUFFIN). Nos nomes dos palestrantes

adotou-se a grafia da programação oficial. Quando a forma correta de um termo é provável mas não certa, isso é indicado no texto.

- **Pontuação e falantes.** O SRT não identifica quem fala. A atribuição de falas foi feita pelo contexto (apresentações do moderador, menções a nomes e mudanças de assunto).
- **Números.** Valores numéricos foram reproduzidos como aparecem na fala. Eles refletem o que foi dito na apresentação e não foram conferidos em outras fontes.
- **Trechos informais.** Entre 3:22 e 3:39 o microfone captou conversas informais e de caráter pessoal após o encerramento da manhã. Por respeito à privacidade dos participantes e por não terem conteúdo técnico, esses trechos não foram analisados.
- **Participantes da plateia.** Pessoas que fizeram perguntas são citadas apenas pelo primeiro nome ou pelo vínculo que elas mesmas declararam ao microfone.
- **Tempos.** Todos os tempos seguem o formato Hora:Minuto:Segundo do arquivo SRT, contados a partir do início do vídeo, e não o horário do relógio no dia do evento.

2. Estrutura do evento

O dia seguiu os dois eixos e os seis palestrantes previstos, com uma única mudança: a keynote de Thiago Oliveira (AVEVA) passou do primeiro para o terceiro horário da manhã.

2.1 Programação prevista e programação realizada

No início de sua fala, Thiago Oliveira explicou que um imprevisto exigiu a troca na agenda e agradeceu a compreensão de todos. Ele observou que a nova ordem acabou formando uma sequência natural: primeiro o contexto industrial, depois os gêmeos digitais e, por fim, a inteligência artificial apoiada nesses dois elementos. O moderador da manhã também reduziu o primeiro coffee break para cerca de 15 minutos, a fim de recuperar o horário. O palestrante Idelfonso Nogueira participou de forma remota, a partir da Noruega.

Ordem	Programação prevista	Ordem realizada (tempo no SRT)
1	Keynote — Thiago Oliveira (AVEVA)	1ª palestra: Thiago Anzai (PETROBRAS), 0:03:10
2	Palestra 1 — Thiago Anzai (PETROBRAS)	2ª palestra: Thiago Feital (OPTIMATECH), 1:34:00
3	Palestra 2 — Thiago Feital (OPTIMATECH)	3ª palestra: keynote de Thiago Oliveira (AVEVA), 2:29:00
4	Keynote — Idelfonso Nogueira (NTNU)	Keynote de Idelfonso Nogueira (NTNU), remota, 4:47:50
5	Palestra 1 — Fabio Santos (LNCC)	Palestra de Fabio Santos (LNCC), 5:55:00
6	Palestra 2 — Americo Cunha (LNCC)	Palestra de Americo Cunha (LNCC), 7:16:30

2.2 Quadro-resumo das palestras

Palestrante e instituição	Título (programação)	Ideia central em uma frase
Thiago Anzai — PETROBRAS (CENPES)	Dos modelos à operação: monitoramento em tempo real e gêmeos digitais na indústria de petróleo e gás	Uma plataforma integradora (Smart Monitor) permite levar modelos de dados, fenomenológicos e híbridos da pesquisa para a operação offshore, na forma de sombras digitais.
Thiago Feital — OPTIMATECH	Gêmeos Digitais em Processos Industriais	O gêmeo digital pode ser para a operação industrial o que a análise de vibração foi para a manutenção: uma "contabilidade física" em tempo real da planta.
Thiago Oliveira — AVEVA	A Nova Engenharia Industrial: Por Que Gêmeos Digitais são a Base da IA e da Sustentabilidade	O gêmeo digital integra e contextualiza os dados de que a IA depende; o engenheiro químico passa a orquestrar tecnologias e pessoas.
Idelfonso Nogueira — NTNU (Noruega)	IA Informada pelo Domínio na Engenharia Química: da Modelagem Híbrida a Modelos de Fundação	O conhecimento de engenharia, embutido na estrutura dos modelos, gera IA mais confiável e mais eficiente em dados e em computação.
Fabio Santos — LNCC	When Scientific Machine Learning Meets Physics: Modeling Thermodynamics, Fluid Flow, and Turbulence	Redes informadas por física e operadores neurais aceleram simulações de escoamento e termodinâmica em até duas ordens de grandeza, com cuidados metodológicos.
Americo Cunha — LNCC	Aprendizado de Máquina Científico: Integrando Física e Dados	A física atua como viés indutivo do aprendizado estatístico; a mesma lógica, com governança e rastreabilidade, é necessária para a IA que gera hipóteses científicas.

3. Índice cronológico por blocos de tempo

O índice abaixo agrupa os temas em blocos de tempo do arquivo SRT (H:MM:SS, contados do início do vídeo). Os tempos são aproximados ao minuto.

Início	Fim	Bloco	Temas tratados
0:00:00	0:03:10	Abertura do eixo Automação e Gêmeos Digitais (Prof. Argemiro)	Origem do termo gêmeo digital; modelo digital, sombra digital e gêmeo digital; apresentação de Thiago Anzai
0:03:10	0:08:00	Anzai — contexto	Plataforma como "fábrica de dados": cerca de 30 mil sensores e terabytes por dia; apenas cerca de 1%

Início	Fim	Bloco	Temas tratados
			dos dados é usado
0:08:00	0:13:00	Anzai — monitoramento	Cartas de Shewhart, avalanche de alarmes, monitoramento multivariável e interpretabilidade
0:13:00	0:16:00	Anzai — tendência setorial	Nuvem de palavras da ANP: inteligência artificial como termo mais frequente em projetos de PD&I de E&P
0:16:00	0:25:00	Anzai — Smart Monitor	"Onda de soluções" digitais; hub integrador entre usuário, TIC e pesquisadores; mais de 400 modelos; prêmio ANP 2024
0:25:00	0:28:30	Anzai — aplicações	Sistemas críticos monitorados; três demandas do usuário: detectar falhas, substituir sensores, estimar vida útil
0:28:30	0:37:00	Anzai — caso 1	Detecção de falha em medidor fiscal de óleo com modelo multivariável treinado na normalidade
0:37:00	0:43:00	Anzai — caso 2	Sensor virtual de vazão na unidade de remoção de sulfato, por regressão simbólica
0:43:00	0:48:00	Anzai — caso 3	Estimativa da vida útil remanescente de membranas, convertida em datas de ação
0:48:00	0:51:00	Anzai — conclusão	Ponte entre PD&I e operação; dados industriais reais como desafio comum
0:51:00	1:14:00	Anzai — perguntas	Manutenção de modelos e concept drift; TOG; incerteza de medição; evolução para gêmeo digital; diagnóstico automatizado; próximos desafios
1:15:00	1:31:00	Intervalo	Coffee break (sem fala legendada)
1:33:00	1:38:00	Apresentação e abertura de Thiago Feital	Trajetória e Optimatech; provocação com o caso de uma empresa brasileira de manutenção preditiva
1:38:00	1:49:00	Feital — diagnóstico da indústria	Manutenção × operação; perguntas simples e difíceis; quatro cenários típicos
1:49:00	1:56:00	Feital — estrutura do gêmeo digital	Descrição, diagnóstico, predição e prescrição
1:56:00	2:13:00	Feital — cinco casos	Diques de mina; pilhas de coprodutos siderúrgicos; gasoduto; perdas em químicos básicos; cozedores de açúcar
2:13:00	2:15:00	Feital — conclusão	Contabilidade física em tempo real; analogia com a

Início	Fim	Bloco	Temas tratados
			navegação de aviões
2:15:00	2:26:00	Feital — perguntas	Papel de modelos híbridos e ML; dosagem de floculante e dados climáticos; retorno financeiro
2:26:00	2:33:00	Apresentação e abertura de Thiago Oliveira	Troca de agenda; "a IA vai substituir o engenheiro químico?"; enquete com a plateia
2:33:00	2:40:00	Oliveira — dados e contexto	IA depende de dados contextualizados; aplicações de IA na engenharia química
2:40:00	2:52:00	Oliveira — três casos	Gêmeo digital integrado do ciclo de CO2; otimização do LCOH de hidrogênio verde; manutenção preditiva em FPSO
2:52:00	3:01:00	Oliveira — LLMs e uso responsável	Assistentes industriais; pensamento crítico; partir do problema; medir adoção; viés
3:01:00	3:07:00	Oliveira — caso e conclusão	Suportes de tubulação por ML; o engenheiro como orquestrador
3:07:00	3:22:00	Oliveira — perguntas	Defasagem de modelos; agentes e alucinações; ML sem código; formação de jovens engenheiros
3:22:00	3:39:00	Encerramento da manhã	Aviso de retorno às 13h30; conversas informais (não analisadas)
3:39:00	4:32:00	Intervalo	Almoço (sem fala legendada)
4:32:00	4:45:00	Preparação	Testes de áudio e de compartilhamento de tela com o palestrante remoto
4:45:00	4:48:00	Abertura do eixo Modelagem Híbrida (Prof. Maurício)	Apresentação de Idelfonso Nogueira
4:48:00	5:02:00	Nogueira — fundamentos	Papel da engenharia química na IA; analogia da criança que aprende uma língua; extrapolação e alucinação
5:02:00	5:24:00	Nogueira — modelos híbridos	Balanço de massa em leito fixo; hipóteses e incerteza epistêmica; rede neural no termo fonte (UDE)
5:24:00	5:40:00	Nogueira — arquiteturas informadas e modelo de fundação	Família PUFFIN com equação de Antoine; representações moleculares; modelo multimodal
5:40:00	5:48:00	Nogueira — perguntas	Caráter inovador da multimodalidade; diferença em

Início	Fim	Bloco	Temas tratados
			relação à estimação de parâmetros; qualidade dos dados
5:48:00	5:55:00	Apresentação de Fabio Santos	Trajetória; ajustes técnicos de projeção
5:55:00	6:05:00	Santos — LNCC e conceitos	LNCC e supercomputação; definição de SciML; aceleração, fechamento e modelos reduzidos
6:05:00	6:12:00	Santos — redes informadas por física	Ciclone (PINN) e flash termodinâmico (TINN)
6:12:00	6:24:00	Santos — operadores neurais	DeepONet e FNO; escoamento em golfadas; Shearlet Neural Operator
6:24:00	6:35:00	Santos — turbulência e conclusão	Fechamento probabilístico por VAE e SINDy; desafios e mensagens finais
6:36:00	6:48:00	Santos — perguntas	Navier-Stokes e IA; dados do modelo de golfadas; limites das PINNs; flash em CFD
6:48:00	7:13:00	Intervalo	Coffee break (sem fala legendada)
7:13:00	7:19:00	Apresentação e contexto de Americo Cunha	Workshop de SciML no LNCC, livro em preparação e artigo de opinião no SIAM News
7:19:00	7:34:00	Cunha — confiança nos modelos	Modelagem física e estatística; incerteza de forma do modelo; horizontes de previsão
7:34:00	8:00:00	Cunha — métodos de SciML	Otimização com restrições; modelos reduzidos (POD, DMD); caixa-cinza; PINNs; ODIL; redes hamiltonianas
8:00:00	8:08:00	Cunha — IA e método científico	Geração de hipóteses por IA; governança, rastreabilidade e repositórios de simulação
8:08:00	8:29:00	Cunha — perguntas	Modelos na pandemia; ODIL × PINN; projeção bayesiana de apurações; governança; ética e dados confidenciais
8:29:00	8:30:46	Encerramento do dia	Agradecimentos e convite para as sessões do dia seguinte

4. Eixo temático 1 — Automação e Gêmeos Digitais (manhã)

A manhã percorreu um caminho do chão de fábrica para a inteligência artificial: monitoramento em tempo real em plataformas de petróleo, gêmeos digitais em indústrias com poucos sensores e, por fim, a IA apoiada em dados integrados.

4.1 Abertura do eixo: modelo digital, sombra digital e gêmeo digital (0:00:00–0:03:10)

O Prof. Argemiro abriu o eixo com uma distinção conceitual que serviria de referência para todo o dia. Ele lembrou que o termo gêmeo digital surgiu por volta de 2002, em trabalho de Grieves (grafado "Magrive" na legenda), e foi difundido por Vickers, da NASA, em 2010; antes, falava-se em "planta virtual". Em seguida, apresentou três categorias, segundo o grau de automação na troca de informações entre o sistema real e o digital:

Categoria	Fluxo de informação	Uso típico citado
Modelo digital (digital model)	Sem troca automatizada entre sistema real e modelo	Estudos e finalidades pontuais
Sombra digital (digital shadow)	Automático em um sentido: da planta para o modelo	Monitoramento de processos
Gêmeo digital (digital twin)	Automático nos dois sentidos, em tempo real	O modelo calcula, otimiza e devolve ações para a planta

4.2 Palestra — Thiago Anzai (PETROBRAS): "Dos modelos à operação" (0:03:10–1:14:00)

Palestrante. Engenheiro de processamento da Petrobras desde 2012, no Centro de Pesquisas (CENPES), em grupo transversal de monitoramento, controle e simulação do processamento primário. É graduado pela Escola de Química e mestre e doutor pelo PEQ/COPPE.

Ideia central. A transformação digital na produção de petróleo só gera valor quando as soluções de pesquisa chegam à operação de forma padronizada e sustentável. Para isso, a Petrobras criou o Smart Monitor, uma plataforma que reúne modelos e os põe em produção como sombras digitais.

Linha de raciocínio.

1. **Abundância de dados, pouco uso.** Uma plataforma típica tem cerca de 30 mil sensores e armazena terabytes por dia. Citando relatório de consultoria (McKinsey, grafada "Maense"), cerca de 99% desses dados ficam apenas armazenados, como "poeira digital"; o operador acompanha de 200 a 300 variáveis.
2. **Limites do monitoramento univariável.** Cartas de controle de Shewhart para 30 mil sensores levariam a uma "avalanche de alarmes": mesmo com alto nível de confiança, os falsos positivos se acumulam e podem reduzir a confiança da equipe de operação.
3. **Monitoramento multivariável.** Como as plantas são muito correlacionadas, modelos que capturam as relações entre variáveis enxergam anomalias invisíveis a sinais isolados. O custo computacional maior foi diluindo-se com o avanço computacional e com técnicas de interpretabilidade de ML.
4. **Tendência setorial.** Na nuvem de palavras publicada pela ANP para os projetos de PD&I de exploração e produção, "inteligência artificial" aparece como termo mais frequente há vários anos (desde cerca de 2022).
5. **Risco da "onda de soluções".** Muitos projetos geram muitos produtos digitais que não conversam entre si nem com a TIC da empresa. Daí a necessidade de um repositório central.

6. **Smart Monitor como hub.** Uma solução intermediária entre programar tudo em Python e contratar plataformas de nuvem completas. Ela integra três agentes: usuário final, TIC e pesquisadores (inclusive de universidades). Reúne mais de 400 modelos (de dados, fenomenológicos e híbridos), a maioria em tempo real, e recebeu o prêmio da ANP em 2024 pela capacidade de integração.
7. **Estágio atual.** O foco é monitoramento (sombra digital); a evolução pretendida vai do monitoramento baseado em condição ao preditivo e prescritivo, rumo ao gêmeo digital.

Três casos, três demandas do usuário.

Demanda	Caso apresentado	Técnica	Resultado relatado
Detectar falhas ainda não identificadas	Medidor fiscal de óleo (auditado pela ANP; falha prolongada pode levar ao fechamento do ponto de medição)	Modelo de aprendizado de máquina multivariável (temperatura, pressão, nível, outras vazões) treinado só com períodos de operação normal; indicador com limite estatístico; comparação entre vazão medida e predita	Falha real identificada; tempo em falha reduzido graças à indicação imediata; após a detecção, diagnóstico pelas contribuições das variáveis
Substituir um sensor que se sabe estar em falha	Vazão na unidade de remoção de sulfato (membranas que tratam a água do mar para injeção)	Sensor virtual por regressão simbólica, gerando equação simples e implementável, treinada logo após a manutenção do sensor físico	Em uso desde janeiro de 2025, conferido por medições não intrusivas; viabiliza a injeção (relação citada de cerca de 5 barris injetados por barril de óleo produzido)
Saber quando agir em um sistema que degrada	Membranas da unidade de remoção de sulfato	Cálculos fenomenológicos (permeabilidade, perda de carga) a partir do historiador PI e projeção até limites operacionais (vida útil remanescente)	Informação entregue como data prevista de limpeza ou de troca, mais útil ao operador do que valores de permeância

Perguntas e debate.

- **Manutenção dos modelos (Prof. Argemiro).** Novos poços mudam o sistema e exigem retreino. Hoje há acompanhamento periódico com as unidades; como isso não escala, a segunda frente é a detecção automática de concept drift, tema de PD&I com a universidade.
- **Teor de óleo em água, TOG (José, pós-doutorando do PEQ).** O foco foi um sensor virtual que se aproxima do TOG gravimétrico medido em terra, usando medições de bordo e outras variáveis. O valor inferido não substitui a medição oficial perante a ANP, mas evita que a operação fique sem informação entre as análises.

- **Incertezas (Márcio, professor da UFBA).** O palestrante reconheceu que a incerteza se propaga dos sensores aos modelos. A prioridade atual está na base: confiabilidade, manutenção e posicionamento dos sensores para fechar balanços. O monitoramento fenomenológico das membranas de CO2, por exemplo, consome quase 90 tags. A incerteza dos sensores virtuais foi apontada como tema para as próximas etapas.
- **Evolução para gêmeo digital e vida útil de fabricante (professor da plateia, que também elogiou a produção artística do palestrante).** Há intenção de fechar o ciclo com a planta, mas isso exige migrar da rede corporativa para a rede de automação. Em alguns sistemas, o modo de operação tem reduzido a vida útil em relação à indicada pelo fabricante, e o monitoramento por condição pode ajudar a reaproximá-las.
- **Diagnóstico automatizado (Prof. Maurício).** As novas versões do Smart Monitor apresentam melhor as contribuições das variáveis; métodos de diagnóstico desenvolvidos na tese do palestrante estão em testes. A decisão segue com a operação. O professor convidou o palestrante para o simpósio do LADES de 24 de novembro, na Casa da Ciência.
- **Próximos desafios (Gabriela, aluna).** Operação, centro de pesquisa e universidade têm objetivos e ritmos diferentes: replicar, aperfeiçoar e evoluir algoritmos. A visão do palestrante é tornar robusta a primeira ponte para garantir perenidade.

Conclusão do bloco. O caso mostra que o gargalo não é só algorítmico, mas organizacional: integrar, sustentar e traduzir resultados em informação objetiva para quem opera. Os dados reais de operação, com as falhas e ruídos naturais desse ambiente, são ao mesmo tempo o desafio e a oportunidade da parceria entre indústria e universidade.

4.3 Palestra — Thiago Feital (OPTIMATECH): "Gêmeos Digitais em Processos Industriais" (1:33:00–2:26:00)

Palestrante. Engenheiro químico formado pela UFRRJ, com mestrado no PEQ/COPPE (a partir de 2007) e atuação como pesquisador em projetos do programa. Em 2015, com colegas, fundou na incubadora da UFRJ a Optimatech, spin-off do PEQ ativa até hoje. Cursou também um MBA no COPPEAD. Atua em modelagem fenomenológica, simulação dinâmica, tratamento de dados, monitoramento e otimização de processos.

Ideia central. Assim como a análise de vibração com acelerômetros baratos se tornou base da manutenção preditiva, o gêmeo digital pode se tornar base da operação industrial. Ele seria uma "contabilidade física" em tempo real, com balanços de massa e energia usados como instrumento permanente de gestão. O palestrante apresentou essa ideia como tese a ser discutida.

Linha de raciocínio.

1. **Provocação inicial.** Uma empresa brasileira de manutenção preditiva para ativos industriais (Tractian, grafada "traction" na legenda) tornou-se "unicórnio" no mês anterior, avaliada em mais de 1 bilhão de dólares. Seu diferencial foi popularizar sensores baratos sobre uma técnica antiga. A pergunta: existem condições semelhantes para o gêmeo digital escalar?
2. **Manutenção × operação.** A manutenção cuida da disponibilidade dos ativos, de forma intermitente e sob demanda. A operação cuida de produção, qualidade e eficiência, de forma contínua e padronizada.

3. **Perguntas simples, respostas difíceis.** Quanto a planta produziu na última hora? Onde estão as perdas? Como estará a qualidade no fim do próximo turno? Qual o impacto de mudar a programação antes de executá-la?
4. **Muitos dados, pouco conhecimento do estado.** Há muitos sensores de vazão, temperatura, pressão e nível, mas poucos de composição e propriedades, que são os que apoiam decisões. Diferentemente do cenário de petróleo apresentado antes, muitas indústrias têm poucos sensores.
5. **Quatro cenários típicos (não "problemas", mas características da indústria).** (a) Decisões baseadas em análises de laboratório que levam horas ou dias, como temperatura de 85% recuperado do diesel, turbidez, sólidos, viscosidade, densidade, sílica, Brix e zinco; (b) contabilidade de componentes (balanços hídricos, de emissões, de energia, de resíduos) feita de forma isolada, com dados dispersos em planilhas; (c) diagnósticos operacionais e análises de cenário feitos offline ou pontualmente; (d) planejamento e controle da produção (PCP) mais maduro, mas desconectado do chão de fábrica.
6. **Arcabouço analítico.** Os cenários foram posicionados nas quatro perguntas da análise de dados: o que está acontecendo (descrição), por que (diagnóstico), o que vai acontecer (predição) e o que fazer (prescrição). A predição é a camada menos praticada na indústria.
7. **O gêmeo digital proposto.** Um pacote de modelos e métodos alimentados por dados e resolvidos em tempo real, cobrindo as quatro camadas (quadro a seguir). O palestrante observou que a classificação modelo, sombra e gêmeo digital ainda não é uma convenção consolidada, porque o termo se aplica a escopos muito diferentes.

Camada	Pergunta	Componentes do gêmeo digital citados
Descrição	O que está acontecendo?	Balanços de massa e energia, sensores virtuais, reconciliação de dados, estimação de estados e parâmetros, tratamento de incertezas
Diagnóstico	Por que está acontecendo?	Detecção e diagnóstico de falhas, anomalias, perdas e desvios
Predição	O que vai acontecer?	Previsão de séries temporais, modelos dinâmicos, aprendizado de máquina, vida útil remanescente
Prescrição	O que devemos fazer?	Otimização, programação da produção, análise de cenários

Cinco casos.

Setor	Desafio	Solução de gêmeo digital	Benefício esperado ou relatado
Mineração — diques de contenção de sedimentos	Alto custo com floculante, dinâmica lenta, poucas medições, risco de sanções ambientais	Balanço hídrico, predição da turbidez (dia seguinte e semana), dados climáticos, estratégias de dosagem e de recirculação, rebaixamento de	Menor custo e risco ambiental, maior previsibilidade (projeto em fase inicial)

Setor	Desafio	Solução de gêmeo digital	Benefício esperado ou relatado
		nível antes das chuvas	
Siderurgia — pilhas de coprodutos	Resíduos ricos em ferro, mas com contaminantes como zinco; receitas feitas por tentativa e erro em planilhas	Integração de dados, otimização da mistura com restrições químicas, balanços de massa, atualização de limites conforme o minério	Maior recuperação de ferro, menos rejeitos, sem prejudicar a qualidade da sinterização
Transporte de gás natural — gasoduto	Projetado para 30 milhões de m^3/dia, operando em cerca de 12 a 15; incerteza de oferta e demanda; decisão sobre estações de compressão	Previsão de vazões uma semana à frente, modelos de escoamento com restrições de pressão, mapas de compressores, programação ótima das estações	Maior estabilidade, menor custo e pegada de carbono, maior vida útil dos equipamentos
Químicos básicos — contabilidade de perdas	Perdas elevadas e difíceis de medir, chegando a valores negativos por incerteza de medição	Balanço global com incertezas de instrumentação, reconciliação de dados e a perda tratada como parâmetro estimado em tempo real	Faixa de incerteza muito menor e identificação das principais fontes de incerteza
Setor sucroenergético — cozedores (cristalizadores) de açúcar	Dez equipamentos em bateladas acopladas; perda do ponto pode dissolver os cristais e perder horas de operação	Programação da produção (diagrama de ocupação) com limites operacionais e número de cozedores ativos	Padronização, estabilidade e redução de bateladas perdidas (aplicação descrita como inédita no setor)

Conclusão do palestrante. Toda empresa tem contabilidade financeira; poucas têm contabilidade física em tempo real. Pela analogia com a aviação, o piloto não espera chegar ao destino para saber se o combustível bastou: o sistema calcula e projeta continuamente. No futuro, operar uma planta complexa sem gêmeo digital pode parecer tão estranho quanto voar sem instrumentos de navegação.

Perguntas e debate.

- **Comentário do moderador.** O Prof. Argemiro destacou a complementaridade com a palestra anterior: lá, muitos sensores e um setor tradicionalmente cauteloso com novas tecnologias; aqui, instrumentação mais enxuta e a dificuldade de levar instrumentação e automação à indústria, papel em que spin-offs e startups têm importância.
- **Modelos híbridos e ML (Daniel).** O modelo deve ser compatível com o nível de instrumentação: com poucos dados, modelos sofisticados não podem ser calibrados com confiança. A empresa usa sobretudo balanços simplificados a parâmetros concentrados, sem CFD, e aplica ML na

previsão de séries temporais, por exemplo para a demanda de gás. O moderador lembrou que a tarde seria dedicada à modelagem híbrida.

- **Dosagem de floculante (professor da plateia).** O professor relatou estudos com redes neurais em tratamento de água, nos quais a modelagem se mostrou desafiadora porque os dados históricos refletiam decisões operacionais baseadas na experiência, sem ensaios sistemáticos, e citou estudo em uma estação de Cubatão (SC). O palestrante explicou que o projeto da mineradora está no início e que abordagens de ML serão testadas. Mencionou trabalhos do Prof. Cristiano na COPPE e um caso de extração de lítio em lagoas de evaporação, com dados climáticos obtidos da internet (vento, umidade, temperatura, precipitação).
- **Retorno do investimento (Paulo, professor).** Quatro dos cinco casos estão concluídos. O palestrante explicou que medir o retorno é difícil quando só se entrega o software; por isso a empresa passou a trabalhar com assinatura, para quantificar ganhos junto ao cliente. Há números expressivos de redução de perdas, mas não foi possível apresentá-los caso a caso.

Conclusão do bloco. O gêmeo digital, nessa visão, não é um painel de sensores, mas um sistema que calcula inventários, propriedades, restrições e cenários. O grau de sofisticação do modelo deve acompanhar o dado disponível, e o tratamento das incertezas foi apontado como frente promissora.

4.4 Keynote — Thiago Oliveira (AVEVA): "A Nova Engenharia Industrial" (2:26:00–3:22:00)

Palestrante. Diretor de suporte técnico de engenharia e simulação para as Américas na AVEVA. É graduado e mestre em engenharia química pela UFRJ, com pós-graduação pela PUC-Rio, MBA pela FGV e especializações executivas internacionais. Tem mais de 20 anos de experiência, inclusive como operador industrial e em laboratório de controle de turno.

Ideia central. A IA só é tão boa quanto os dados e o contexto que recebe, e o gêmeo digital é o elemento que integra e contextualiza esses dados. Nesse cenário, o engenheiro químico deixa de ser executor de tarefas e passa a orquestrar tecnologias, processos e pessoas, usando a IA como "catapulta" e não como "avatar".

Linha de raciocínio.

1. **Pergunta provocadora.** Em 10 anos, a IA vai substituir o engenheiro químico ou torná-lo mais essencial? O palestrante reconheceu que ninguém tem essa resposta e que existe receio, no chão de fábrica, de que compartilhar experiência signifique ser substituído. Uma enquete rápida mostrou que quase todos usam LLMs, menos pessoas criaram agentes e algumas já desenvolveram modelos de ML, o que ilustra a flexibilidade da profissão.
2. **Dado com contexto.** A IA não faz mágica sem dados. Uma temperatura isolada vale menos do que a mesma variável acompanhada das condições de operação, do clima e de outros sistemas. O gêmeo digital atua como acoplador e consolidador de fontes de informação.
3. **Aplicações de IA na engenharia química.** Otimização de processos, manutenção preditiva, controle de qualidade automatizado e descoberta de materiais. Exemplos: visão computacional que detectava impurezas em fardos de borracha SBR há mais de 20 anos (na antiga Petroflex, hoje Arlanxeo); a "inteligência natural" de técnicos experientes que antecipavam resultados de laboratório, hoje reproduzida por modelos que preveem análises e encurtam o tempo de resposta.

4. **Romper silos.** Os casos mostram ganhos quando disciplinas antes isoladas passam a compartilhar dados.
5. **LLMs e assistentes industriais.** São agentes com contexto e funções específicas da indústria, baseados na documentação da planta. Não substituem o humano, mas poupam o tempo do engenheiro.
6. **Uso crítico e responsável.** Pedido explícito aos futuros engenheiros: sempre revisar e questionar as saídas da IA, mantendo o próprio julgamento no centro das decisões. Na indústria, o uso responsável envolve vidas e a qualidade de produtos, sobretudo quando valores preditos substituem análises formais.
7. **Problema antes da ferramenta.** O palestrante observou que é comum surgir o interesse em adotar IA antes de se definir o problema a resolver. A recomendação é partir de um problema real de engenharia e só então escolher entre IA generativa, ML, redes neurais, LLMs ou modelos híbridos.
8. **Medir resultados e adoção.** Um modelo treinado em parte do espaço operacional dá respostas imprecisas fora dele, e LLMs podem ter viés. Por isso é preciso medir adoção, uso e resultados e ajustar o modelo ou treinar os usuários.

Casos apresentados.

Caso	O que foi feito	Resultado relatado
Gêmeo digital integrado do ciclo de CO2 (Galp, cerca de 2 anos antes)	Integração de simuladores multifásicos do reservatório e do sistema submarino com simuladores de processo do topside de um FPSO, mais representação 3D do ativo	Estudos conjuntos de aumento de produção e redução de emissões de CO2 que antes eram feitos em silos
Otimização do LCOH (custo nivelado do hidrogênio) para hidrogênio verde (desenvolvimento interno)	Dimensionamento com o simulador AVEVA Process Simulation; digitalização automática do terreno com dados públicos de georreferenciamento; otimização da posição de turbinas eólicas e do cabeamento	Redução citada de cerca de 98% no custo da etapa de FEED; estudos de localização sem ir ao local
Manutenção preditiva no FPSO P-50 (Albacora Leste, cerca de 2019)	Verificação da consistência entre P&IDs e modelo 3D; modelos de predição por clusterização de estados operacionais; alarme quando a planta se descola do modelo de IA	Antecipação de falhas; possibilidade de estender paradas programadas quando os equipamentos estão saudáveis
Suportes de tubulação por ML (empresa brasileira, descrita como pioneira mundial)	Três modelos de ML em paralelo: quantidade, posição e tipo de suporte	12 suportes preliminares em 25 s e detalhados em 46 s; redução de 20% na modelagem, 60% nas análises de flexibilidade, 35% no projeto e mais de 90% na análise de tipo e posição

O palestrante lembrou que esse último caso foi feito com ML "sem código" e associou a abordagem de clusterização ao trabalho com dados de hidrotratamento (HDT) que fez na graduação com o Prof. Maurício.

Perguntas e debate.

- **Defasagem de modelos (participante).** Simuladores integrados a sistemas PI de informação de planta mostram quando o modelo deixa de ser fiel. No caso apresentado, a atualização é manual, embora a atualização contínua seja tecnologicamente possível.
- **Agentes e alucinações (Márcio, professor da UFBA).** O professor observou que concorrentes evitam deixar o agente fazer contas, entregando-lhe ferramentas de cálculo. O palestrante descreveu três tecnologias em uso: IA generativa para traçado de tubulações com restrições do usuário; assistente industrial que consulta manuais e faz buscas em linguagem natural em modelos 3D, P&IDs e PFDs, ou avalia modelos de simulação frente a boas práticas; e ML sem código, que testa modelos de regressão e indica o melhor R^2, cabendo ao engenheiro escolher dados que reflitam a física do processo.
- **Formação de jovens engenheiros (Prof. Maurício).** O professor citou pesquisa recente de Stanford que indicou queda de contratações de jovens de 22 a 25 anos em funções expostas à IA nos EUA. O palestrante ponderou que estudos desse tipo devem ser interpretados à luz do contexto em que foram feitos e relatou contratações recentes de recém-formados em sua equipe. Para os estudantes, sugeriu: estatística como base da IA, depois Python e bibliotecas de engenharia química, depois IA aplicada à indústria. Pediu ainda cuidado com dados confidenciais em LLMs públicos e revisão atenta de textos gerados por IA, para preservar a credibilidade.

Conclusão do bloco. O papel do engenheiro químico está em expansão, não em extinção. A IA deve liberar o profissional de tarefas repetitivas para que ele aplique o conhecimento que levou anos para construir, com pensamento crítico e uso responsável.

4.5 Síntese do eixo Automação e Gêmeos Digitais

Os três palestrantes partiram de realidades distintas e chegaram a conclusões convergentes.

Dimensão	Anzai (PETROBRAS)	Feital (OPTIMATECH)	Oliveira (AVEVA)
Realidade de dados	Grande número de sensores, com cerca de 1% dos dados em uso	Instrumentação mais enxuta, com poucas medições de composição e propriedades	Dados distribuídos entre sistemas, que precisam ser contextualizados
Estágio de gêmeo digital	Sombra digital (monitoramento), rumo ao gêmeo completo	Gêmeo digital como sistema de cálculo para a operação	Gêmeo digital como base de dados contextualizados para a IA
Modelos predominantes	Dados, fenomenológicos e híbridos	Balanços simplificados, reconciliação, otimização e previsão	ML, IA generativa, assistentes baseados em LLMs

Dimensão	Anzai (PETROBRAS)	Feital (OPTIMATECH)	Oliveira (AVEVA)
Desafio principal	Integração, sustentação e tradução para a operação	Instrumentação, integração de dados e quantificação de retorno	Adoção, problema bem definido e uso responsável

Três pontos aparecem nas três falas. Primeiro, a informação precisa chegar à operação de forma objetiva: datas, alarmes, receitas e programações, e não grandezas abstratas. Segundo, os modelos se degradam com mudanças no processo e exigem manutenção e retreino. Terceiro, a qualidade e a incerteza das medições condicionam tudo o que vem depois, tema levantado nas perguntas e apontado por Feital como aposta para o futuro.

5. Eixo temático 2 — Modelagem Híbrida (tarde)

A tarde tratou de como combinar conhecimento físico e aprendizado a partir de dados. O percurso foi da modelagem híbrida em engenharia química até modelos de fundação, operadores neurais e governança da IA na ciência.

5.1 Keynote — Idelfonso Nogueira (NTNU): "IA Informada pelo Domínio na Engenharia Química" (4:45:00–5:48:00)

Palestrante (participação remota, a partir da Noruega). Professor associado do Departamento de Engenharia Química da NTNU e fundador de uma startup (grafada "Buffin Hub" na legenda). Tem mestrado em engenharia industrial pela UFBA e mestrado integrado e doutorado pela Universidade do Porto. Preside, desde abril deste ano, a seção de inteligência artificial em engenharia química da Federação Europeia de Engenharia Química (EFCE). Co-coordena o comitê Nordic Process Control e representa a Noruega no comitê de engenharia de processos e sistemas da EFCE. Seu grupo de pesquisa combina IA e engenharia de processos.

Ideia central. Engenheiros químicos conhecem a "gramática" dos processos: as regras, as hipóteses e sobretudo as exceções. Levar esse conhecimento para dentro das arquiteturas de IA produz modelos que extrapolam com coerência física, precisam de menos dados e de menos computação.

Linha de raciocínio.

1. **Por que a engenharia deve participar da IA.** A EFCE identificou a necessidade de esclarecer o papel da engenharia química na transformação digital e de trazer sistematização ao "nevoeiro" atual da IA.
2. **Analogia da criança que aprende inglês.** Aprendendo só por padrões, a criança generaliza a regra da média (passado com "-ed") e erra nos verbos irregulares ("go"). Na escola, a gramática ensina as exceções ("went"). Do mesmo modo, um modelo que aprende só com dados extrapola pela média. A engenharia vive de exceções, como deslocar um equilíbrio químico retirando o produto (por exemplo, em destilação reativa).
3. **Alucinação e extrapolação.** Modelos de linguagem podem inventar referências, e modelos orientados a dados também "alucinam" fora da região de treino: uma curva de saturação pode ser extrapolada como parábola descendente. Formas funcionais com limite assintótico, como a isoterma de Langmuir, garantem o comportamento esperado.

4. **Hipóteses e incerteza epistêmica.** No balanço de massa de um leito fixo de adsorção (acumulação, convecção, dispersão axial e termo fonte), cada termo carrega hipóteses: porosidade uniforme, gás ideal, velocidade constante, ausência de gradientes radiais, difusão fickiana unidimensional, força motriz linear (LDF), forma da isoterma, sistema isotérmico e monocomponente. O termo fonte concentra a maior incerteza, pois resume equilíbrio, cinética, transferência de massa e competição entre componentes. Simulações com isotermas de Langmuir, linear e de Freundlich e com diferentes coeficientes LDF e números de Péclet mostraram como as hipóteses mudam as curvas de ruptura.
5. **Quando usar IA.** Se o sistema é bem conhecido e o custo computacional é aceitável, talvez a IA nem seja necessária. A IA é útil quando parte do fenômeno não pode ser caracterizada com confiança. A decisão exige análise crítica do sistema e da aplicação.
6. **Modelo híbrido do tipo UDE.** Uma rede neural substitui apenas o termo incerto (o equilíbrio de adsorção) dentro da equação diferencial parcial. Para treinar, resolve-se numericamente a EDP e compara-se a concentração calculada com a observada. Assim, a forma do balanço transfere conhecimento para os parâmetros da rede, e toda predição passa pelo balanço de massa. Em teste com dados de concentração apenas entre 0 e 1, o modelo puramente de dados divergiu fora da faixa, enquanto os modelos híbridos chegaram ao patamar físico esperado. Outras formas de hibridação, como neural ODEs, foram mencionadas.
7. **Viés indutivo na arquitetura: família PUFFIN.** Para triagem rápida de moléculas (solventes de captura de CO2, fluidos de refrigeração de data centers), a forma funcional da equação de Antoine é embutida na saída da rede. A rede prevê a pressão de vapor, e o erro em relação ao dado experimental é retropropagado. Isso garante extrapolação coerente em temperatura, como mostrado para o benzeno. A abordagem foi estendida à viscosidade.
8. **Uso eficiente dos dados: representações moleculares.** SMILES (texto), impressões digitais de Morgan, grafos e imagens 3D trazem informações diferentes da mesma molécula, como forma, tamanho e polarizabilidade.
9. **Modelo de fundação multimodal (MultiPUFFIN, grafia provável).** Desenvolvido na tese da doutoranda Karine, segundo o palestrante. Codificadores específicos (transformer para texto, CNN para imagem, rede de grafos para grafos, entre outros) geram embeddings fundidos em um espaço latente comum. O modelo tolera modalidades ausentes e prevê várias propriedades termodinâmicas, cada uma restrita por sua forma funcional.
10. **Acoplamento com modelos de processo.** O modelo de fundação foi estendido a propriedades de adsorção e acoplado ao modelo de leito fixo, prevendo o comportamento do processo.

Resultados relatados para o modelo de fundação.

Aspecto	MultiPUFFIN (relatado)	Referência de comparação citada
Moléculas de treino	Cerca de 37 a 38 mil	ChemBERTa-2: 77 milhões
Volume de dados frente a outros modelos de fundação	Cerca de 200 vezes menos dados (afirmação do palestrante)	—
Infraestrutura de treino	Notebook com placa gráfica comercial	Servidores de grande porte

Aspecto	MultiPUFFIN (relatado)	Referência de comparação citada
Propriedades termodinâmicas	Previsão direta, com restrição termodinâmica	Não previa diretamente; quando adaptado, teve desempenho inferior

Perguntas e debate.

- **Caráter inovador (Prof. Maurício).** O palestrante considera a abordagem inovadora pela união de multimodalidade e restrição por conhecimento de domínio. Segundo ele, na época da publicação não havia modelo correlato com as duas características.
- **Diferença em relação à estimação de parâmetros (Marcelo, UFRJ).** Na estimação clássica, compara-se parâmetros previstos com parâmetros conhecidos. Como infinitas combinações de A, B e C podem produzir o mesmo resultado (o fenômeno de "sloppiness"), a rede é treinada na propriedade final. O essencial é a forma funcional, não os valores dos parâmetros.
- **Confiabilidade dos dados (professor da plateia).** Os dados vieram de fontes curadas, como NIST e REFPROP, e de publicações de grupos de referência reconhecida.

Conclusão do bloco. Engenheiros não devem ser apenas usuários de modelos de IA, mas contribuir com seu conhecimento para construí-los. Os modelos apresentados estão, ou estarão em breve, disponíveis em código aberto.

5.2 Palestra — Fabio Santos (LNCC): "When Scientific Machine Learning Meets Physics" (5:48:00–6:48:00)

Palestrante. Engenheiro químico pela UFRJ, com mestrado e doutorado no PEQ/COPPE e pós-doutorado em matemática aplicada no IMPA. Foi professor da Escola de Química da UFRJ, da UERJ e do Programa de Engenharia de Sistemas e Computação da COPPE, além de professor visitante na Johns Hopkins University, com o Fulbright Junior Professor Award. É pesquisador do LNCC (MCTI), membro da SBMAC e bolsista do Instituto Serrapilheira e do programa Jovem Cientista da FAPERJ. Trabalha com escoamentos multifásicos e turbulentos, CFD, computação em GPU, computação quântica e aprendizado de máquina baseado em física.

Ideia central. O aprendizado de máquina científico (SciML) usa técnicas de ML para acelerar a solução de problemas científicos respeitando restrições físicas e matemáticas. Ele traz ganhos reais de velocidade, mas não é "bala de prata": a física imposta pela função objetivo é satisfeita apenas em média.

Contexto institucional. O LNCC é uma unidade de pesquisa do MCTI criada em 1980, com pós-graduação interdisciplinar. Abriga o supercomputador mais rápido da América Latina dedicado à ciência, com 18,85 petaflops, e prevê uma ampliação para cerca de 700 petaflops, com horizonte mencionado em torno de 2027. Tem um Instituto de IA que inclui o desenvolvimento de LLMs nacionais, citados na legenda como "Manacá" e "Carcará". O palestrante atua nas áreas de SciML para mecânica do contínuo e de algoritmos quânticos.

Linha de raciocínio.

1. **Onde está o SciML.** Com base em um esquema de artigo de Karniadakis na Nature, o palestrante situou o SciML entre dois extremos: muita física e poucos dados (métodos clássicos como elementos e volumes finitos) e muitos dados sem física (ML puro). Ajustar parâmetros de modelos físicos com dados já era, em certa medida, uma forma disso.
2. **Quatro usos em escoamentos.** Acelerar a solução (aprender operadores de discretização, corrigir malhas grossas, servir de pré-condicionador); melhorar modelos (substituir modelos de turbulência por regressão simbólica ou ML); gerar modelos reduzidos (projeção em espaço latente com autoencoders, por exemplo); e sensoriamento e gêmeos digitais.
3. **Onde entra a física.** Como o treino é uma otimização, leis de conservação, simetrias, estabilidade e restrições termodinâmicas entram na função objetivo. A convergência é em média, em sentido integral, e não volume a volume como nos métodos conservativos. Por isso o palestrante prefere "informado por" a "informado por física": pode ser termodinâmica, biologia ou qualquer equação.
4. **Redes informadas por física: dois casos.** (a) Ciclone separador: dados de 300 simulações RANS com diferentes números de Reynolds, resíduos de Navier-Stokes e condições de contorno na função perda. (b) Flash termodinâmico (TINN): em CFD, cada célula pode exigir um cálculo de flash, e uma malha de 1 milhão de nós exige 1 milhão de flashes. A rede respeita equilíbrio de fases (igualdade de potenciais químicos), balanço de massa e minimização da energia livre de Gibbs, com um classificador de estabilidade de fases e recurso ao flash clássico quando necessário.
5. **Operadores neurais.** Uma rede neural clássica mapeia vetores em vetores; um operador neural mapeia funções em funções, o que o torna independente da malha. Foram apresentadas duas arquiteturas com teoremas de aproximação universal: DeepONet (redes "branch" e "trunk" combinadas por produto interno, apoiada no teorema de Chen e Chen, de 1995) e FNO (Fourier Neural Operator, que aprende no espaço de Fourier, com teorema de 2021).
6. **Sensoriamento virtual em escoamento em golfadas.** Uma DeepONet treinada com dados de simulador mapeia medições de dois sensores, na entrada e na saída de uma tubulação, no campo interno. As restrições incluíam conservação de massa e soma das frações de fase igual a 1. Treinado em uma janela de tempo, o modelo estimou a dinâmica em janela posterior em cerca de 1 segundo.
7. **Um operador neural próprio: Shearlet Neural Operator (SNO).** A transformada de Fourier sofre com o fenômeno de Gibbs em descontinuidades, como interfaces, ondas de choque e turbulência. A equipe adotou a base de shearlets, sensível a escala e direção, provou convergência mais rápida e aproximação universal e testou o método em cerca de sete a oito benchmarks. O erro L2 foi quase sempre menor que o do FNO, sobretudo em problemas anisotrópicos, como convecção com descontinuidade e equação de Burgers com choques. Já foi aplicado a mapeamento de rochas e a problemas inversos; turbulência e separadores supersônicos são os próximos alvos.
8. **Fechamento de turbulência probabilístico.** Em modelos "shell" (versões simplificadas de Navier-Stokes no espaço de Fourier), os modos cortados precisam de fechamento. Foram usados um autoencoder variacional (VAE), modelo generativo que aprende uma distribuição latente, e o SINDy, regressão esparsa que identifica equações diferenciais interpretáveis a partir de dados. Ambos reproduziram os momentos estatísticos e o fluxo de energia entre modos (artigo publicado na revista Chaos).

Resultados relatados.

Aplicação	Método	Ganho ou desempenho relatado
Ciclone separador	PINN 3D com Navier-Stokes	Cerca de 200 vezes mais rápido que CFD; desvio de cerca de 5% em relação ao experimental; base para otimizar a geometria
Flash em células de CFD	Rede informada por termodinâmica (TINN) com classificador	De 5 a 200 vezes mais rápido por célula; erro de cerca de 6% frente ao dado experimental
Escoamento em golfadas	DeepONet	Estimativa em cerca de 1 s; R^2 de aproximadamente 0,6 a 0,7, ainda em validação
Problemas descontínuos e anisotrópicos	Shearlet Neural Operator	Erro L2 menor que o do FNO na maioria dos benchmarks
Fechamento de turbulência (modelo shell)	VAE e SINDy	Momentos da distribuição e fluxo de energia bem capturados

Desafios e mensagens finais. Treinar não é simples e gerar dados é caro, pois uma simulação de CFD pode levar meses. Há oportunidades em sensoriamento, super-resolução (embora a invariância à malha seja debatida por matemáticos) e problemas inversos, inclusive inversão sísmica. A computação de alto desempenho é indispensável, e o palestrante convidou o público a conhecer o LNCC, em Petrópolis, e seu curso de verão. Em sua opinião, o ML não substituirá os modelos físicos por ora, mas sua integração com física e matemática é um caminho sem volta. Quantificação de incertezas e benchmarks seguem como problemas abertos.

Perguntas e debate.

- **Resultado recente sobre Navier-Stokes obtido com IA (Juan).** O palestrante preferiu não opinar sobre o mérito, lembrando que a comunidade ainda avalia o trabalho. Observou que o tema ultrapassou a matemática e levou a refletir sobre o papel do cientista e sobre o modelo de ciência.
- **Dados do modelo de golfadas e limites das PINNs (participante).** Os dados vieram de um simulador comercial de escoamento multifásico: pressão, velocidade e composição das duas fases na entrada e na saída, em trabalho de doutorado em andamento. Sobre as PINNs como restrição "suave", o palestrante disse que não as usaria para problemas diretos, em que elementos e volumes finitos têm matemática madura e menos heurística. Elas têm vantagem em problemas inversos, em casos de modelo fraco com dados suficientes e como regularização de operadores neurais e modelos reduzidos. Grupos do LNCC estudam combinar elementos finitos com PINNs como bases multiescala.
- **Flash em CFD (Hugo).** As entradas são temperatura, pressão e composição global. Um classificador supervisionado, com limiar de 50%, indica se há duas fases; nesse caso, a rede

fornece a fração vaporizada e as composições das fases, substituindo o flash iterativo que dominaria o custo da simulação.

5.3 Palestra — Americo Cunha (LNCC): "Aprendizado de Máquina Científico: Integrando Física e Dados" (7:13:00–8:30:46)

Palestrante. Pesquisador do LNCC e professor associado de matemática aplicada da UERJ. Pesquisa dinâmica não linear, quantificação de incertezas, aprendizado de máquina científico e modelagem orientada por dados. Integra o corpo editorial de periódicos como Nonlinear Dynamics, ASME Journal of Vibration and Acoustics e Journal of Vibration Engineering and Technologies. Recebeu o prêmio ABCM de jovem cientista em 2023 e foi pesquisador visitante em instituições como Princeton e Georgia Tech, entre outras.

Contexto da fala. A apresentação se baseou nos dois primeiros capítulos de um livro sobre aprendizado de máquina científico, resultado de um workshop sobre SciML para modelagem preditiva realizado no LNCC no ano anterior, com publicação prevista para o próximo ano. Coautores citados: Fabio Santos, Fernando Rochinha, Álvaro Coutinho, José Hugo e Rafael Abreu. A parte final retomou um artigo de opinião do palestrante aceito no SIAM News na véspera da palestra. O palestrante avisou que haveria alguma sobreposição com a palestra anterior.

Ideia central. Todo modelo deve ser usado com senso crítico. A física, usada como viés indutivo, torna o aprendizado estatístico mais confiável. Agora que a IA também gera hipóteses científicas, é preciso um caminho análogo, com conhecimento de domínio, governança, rastreabilidade e repositórios padronizados.

Linha de raciocínio.

1. **Podemos confiar nos modelos?** Após cerca de 25 anos de simulação, o palestrante descreveu sua confiança como "desconfiada". Mesmo onde a física é bem conhecida, há condições de contorno incertas, propriedades tabeladas fora das condições reais, termos esquecidos, erros de programação e fechamentos aproximados (RANS, LES, mecanismos de dissipação). Isso é a incerteza na forma do modelo. Em economia, epidemiologia, biologia e neurociência, o conhecimento dos mecanismos é ainda mais limitado.
2. **Modelagem física.** Os cinco princípios (conservação de massa, energia, quantidade de movimento linear e angular, e segunda lei da termodinâmica) mais hipóteses e equações constitutivas levam a um operador $N(u, \theta) = 0$. As virtudes são interpretabilidade e extrapolação dentro do domínio de validade das hipóteses.
3. **Modelagem estatística.** Modelos autorregressivos preveem bem a curto prazo, como o câmbio algumas semanas à frente, desde que não haja eventos exógenos. Regressão, identificação de sistemas, redes neurais, processos gaussianos, árvores de decisão e operador de Koopman detectam padrões recorrentes, mas falham quando o futuro não repete o passado.
4. **Aprendizado estatístico é otimização.** Treinar é, na grande maioria dos casos, minimizar uma função perda entre previsões e observações. Uma rede neural não tem "obrigação" de conservar massa, e fora do domínio de treino o desempenho tende a cair bastante.
5. **Física como viés indutivo.** As leis de conservação entram como restrições da otimização, incorporadas por um lagrangiano aumentado, como no cálculo com multiplicadores de Lagrange. A ideia foi popularizada pelo grupo de George Karniadakis, da Brown University. O

resultado é aproximado tanto nos dados quanto na física. A ideia de combinar dados e modelos não é nova: a assimilação de dados existe há décadas, com destaque para a meteorologia.

6. **Panorama de técnicas.** Modelos reduzidos e substitutos (POD, parente da análise de componentes principais, e DMD), que o palestrante recomenda ver também como aprendizado estatístico; modelos híbridos ou caixa-cinza, com correção aprendida a partir de dados de alta fidelidade, como DNS, ou de erros históricos, e exemplo de biorreator com taxa de crescimento representada por regressor; PINNs; ODIL; redes neurais hamiltonianas; SINDy; e operadores neurais.
7. **PINNs: virtudes e limites.** São independentes de malha e aprendem com pouca informação, mas a otimização é de alta dimensão e mal condicionada, com viés espectral (frequências altas aprendidas por último), satisfação apenas média da EDP e sensibilidade a hiperparâmetros. A maior vantagem está em problemas inversos.
8. **ODIL (Optimizing a Discrete Loss).** Em vez do resíduo contínuo, usa o resíduo discreto de um esquema numérico, como Crank-Nicolson, e estima simultaneamente o campo e os coeficientes desconhecidos, sem resolver a EDP a cada iteração. Isso aproveita diferenciação automática e otimizadores determinísticos. O palestrante citou que o artigo original, do grupo de Petros Koumoutsakos, relatou ganhos médios da ordem de 100 mil vezes frente a PINNs.
9. **IA na geração de hipóteses.** A IA generativa produz mais hipóteses do que conseguimos validar, e plausibilidade não é garantia. Hipóteses só têm validade científica após escrutínio pelo método científico. São necessárias explicabilidade, rastreabilidade e transparência epistêmica. A proposta, ainda inicial, é um sistema governado: gerar hipóteses, checar restrições de domínio, instanciar simulações, avaliar e validar, com versionamento e proveniência.
10. **Repositórios de simulações.** Pesquisadores refazem simulações caras porque há poucos repositórios públicos e faltam metadados, como condições de contorno e tolerâncias. A comunidade de ciência e engenharia computacional poderia seguir o exemplo dos bancos de dados de proteínas da biologia computacional. O palestrante convidou a COPPE a liderar essa discussão no Brasil e mencionou o congresso do ano seguinte no Rio de Janeiro (grafado "silance" na legenda, provavelmente o CILAMCE).

Comparação ODIL × PINN apresentada pelo palestrante (equação de Burgers).

Cenário de dados	Melhor desempenho	Observação
12 mil, 9 mil, 6 mil e 3 mil pontos	ODIL	Superior em acurácia; em média cerca de 3 vezes mais rápido no problema simples
Cerca de 1% da informação original	PINN	Aprende melhor com informação escassa, mas leva mais tempo

Perguntas e debate.

- **Modelos durante a pandemia (Juan).** Muitos grupos, com trajetórias e experiências diversas, contribuíram com previsões naquele período. Modelos epidemiológicos têm horizonte curto, de semanas a poucos meses. Os dados são pouco informativos e há retroalimentação: a própria previsão muda o comportamento das pessoas. Na previsão do tempo, o limite vem do caos. Em ambos os casos, o aprendizado estatístico tem estendido o horizonte útil.

- **ODIL × PINN (Leonardo, doutorando do PEQ).** ODIL é preferível quando há geometria tratável e um bom esquema numérico conhecido, pois a perda discreta é mais bem comportada para métodos de gradiente determinísticos. PINN é preferível com informação muito escassa ou em dimensão muito alta. Para problemas paramétricos, o palestrante defendeu que resolver muitas vezes com ODIL e interpolar pode competir com a parametrização única e demorada das PINNs.
- **Projeções durante a apuração eleitoral (Hugo).** O palestrante explicou o exemplo como modelagem híbrida e bayesiana: conhecem-se a ordem típica de chegada das urnas e o padrão histórico de cada seção. A cada urna apurada, mede-se o desvio em relação ao padrão e atualiza-se a previsão, que vai estreitando. A técnica é conhecida pela estatística há décadas.
- **Governança para validar resultados obtidos com IA (Prof. Maurício).** O texto aponta lacunas e uma arquitetura geral, não mecanismos detalhados. Não haverá governança universal nem estática: cada área terá a sua, e ela evoluirá. O palestrante propôs um workshop envolvendo instituições do Rio de Janeiro e, depois, do restante do país, e relatou contato com a associação internacional de mecânica computacional (IACM, grafia provável). Fabio Santos acrescentou que há uma iniciativa para integrar IA e matemática aplicada entre IMPA, LNCC, CBPF e UFRJ, e que as duas palestras serviam como convite à comunidade de engenharia química da COPPE.
- **Interdisciplinaridade e cuidado com dados.** O palestrante afirmou que passou a precisar aprender governança, ética e legislação. Recomendou não inserir informações confidenciais ou pessoais em ferramentas de IA, porque não se sabe onde esses dados serão usados.

Conclusão do bloco. O SciML aumentou a confiabilidade do aprendizado estatístico ao incorporar a física. O próximo passo é dar à IA que produz conhecimento as mesmas garantias, o que exige incorporar domínio, governança e ética e aproxima as ciências exatas das humanas.

5.4 Síntese do eixo e encerramento do dia

Os três palestrantes da tarde concordaram que o conhecimento físico deve guiar o aprendizado a partir de dados, mas mostraram três formas de fazer isso.

Onde entra o conhecimento físico	Exemplos do dia	Palestrantes
Na estrutura do modelo: rede dentro de uma equação diferencial	UDE no termo fonte do leito fixo; modelos caixa-cinza	Nogueira, Cunha
Na arquitetura: forma funcional embutida na saída	PUFFIN com equação de Antoine; redes hamiltonianas	Nogueira, Cunha
Na função perda: resíduo como penalidade	PINN no ciclone; TINN no flash; operadores neurais com restrições	Santos, Cunha
No resíduo discreto do método numérico	ODIL	Cunha
Na descoberta da própria equação	SINDy; regressão simbólica	Santos, Cunha (e Anzai, de manhã)

As falas também se complementaram em um ponto técnico. Nogueira mostrou que a restrição embutida na estrutura do modelo mantém as previsões coerentes com a física. Santos e Cunha

acrescentaram que, quando a física entra apenas pela função perda, ela é satisfeita em média. Para problemas diretos bem resolvidos, métodos numéricos clássicos ou ODIL podem ser mais eficientes que PINNs. As abordagens não se excluem, e a escolha depende do conhecimento disponível, dos dados e do objetivo.

Encerramento (8:29:00–8:30:46). O Prof. Maurício agradeceu aos palestrantes e observou que a discussão final sobre ética fazia a ponte com o dia seguinte. A sessão da manhã seguinte trataria do uso da IA e de seus aspectos éticos, inclusive em educação e formação, e à tarde haveria uma mesa-redonda com título propositalmente aberto. Americo Cunha agradeceu à organização pela adaptação da data do evento.

6. Glossário de conceitos de IA e Machine Learning discutidos

O quadro reúne as ferramentas e os conceitos de IA e ML mencionados ao longo do dia, com uma definição sintética e a aplicação mostrada em cada palestra. As definições seguem o uso dos palestrantes, complementado pela acepção usual na literatura. Os grupos estão em ordem crescente de especialização.

6.1 Conceitos gerais e aprendizado de máquina clássico

Conceito	Definição	Aplicação no evento (palestrante)
Inteligência artificial (IA)	Campo que desenvolve sistemas capazes de realizar tarefas associadas à inteligência humana, como reconhecer padrões, prever e gerar conteúdo	Termo mais frequente nos projetos de PD&I de E&P registrados na ANP (Anzai); visão geral de suas vertentes (Oliveira)
Aprendizado de máquina (ML) e aprendizado estatístico	Algoritmos que ajustam parâmetros a partir de dados, em geral minimizando uma função perda	Base de quase todos os casos; descrito como "problema de otimização" (Cunha, Santos)
Função perda	Medida da distância entre previsões do modelo e observações, minimizada no treino	Ponto onde a física pode entrar como penalidade (Santos, Cunha)
Modelo orientado a dados (caixa-preta)	Modelo que aprende padrões apenas dos dados, sem estrutura física	Bom ajuste dentro da faixa de treino e extrapolação pouco confiável (Nogueira, Cunha)
Detecção de anomalias com modelo treinado na normalidade	Modelo aprende a relação entre variáveis em operação normal; desvios acima de um limite estatístico indicam falha ou novidade	Medidor fiscal de óleo (Anzai)
Monitoramento multivariável e método das	Consolidação de muitas variáveis correlacionadas em um indicador; as contribuições apontam as variáveis mais	Detecção e diagnóstico no Smart Monitor (Anzai)

Conceito	Definição	Aplicação no evento (palestrante)
contribuições	responsáveis pelo desvio	
Sensor virtual (soft sensor)	Modelo que estima uma variável não medida, ou de sensor em falha, a partir de outras medidas	Vazão na remoção de sulfato, TOG (Anzai); componente do gêmeo digital (Feital); escoamento em golfadas (Santos)
Regressão simbólica	Busca de uma expressão matemática explícita que ajuste os dados	Sensor virtual implementável como equação simples (Anzai); alternativa a modelos de turbulência (Santos)
Vida útil remanescente (RUL)	Estimativa do tempo até um equipamento atingir um limite operacional	Datas de limpeza e troca de membranas (Anzai); camada de predição (Feital)
Concept drift	Mudança nas relações entre variáveis ao longo do tempo, que degrada modelos treinados	Novos poços exigem retreino (Anzai); defasagem de modelos (Oliveira)
Manutenção preditiva	Antecipação de falhas a partir de dados de condição, em lugar de manutenção corretiva ou por calendário	Analogia com a análise de vibração (Feital); FPSO P-50 e extensão de paradas programadas (Oliveira)
Clusterização	Agrupamento não supervisionado de dados semelhantes, por exemplo, estados operacionais	Predição de falhas no FPSO; trabalho com dados de HDT (Oliveira)
Visão computacional	Algoritmos que interpretam imagens	Detecção de contaminantes em fardos de borracha SBR (Oliveira)
Previsão de séries temporais e modelos autorregressivos	Modelos que projetam valores futuros a partir do histórico	Vazões de gás uma semana à frente (Feital); câmbio e epidemias em horizonte curto (Cunha)
Redes neurais e aprendizado profundo	Modelos compostos por camadas de neurônios artificiais, aproximadores flexíveis de funções	Termo fonte de modelos híbridos (Nogueira); PINNs e operadores (Santos, Cunha)
Processos gaussianos e árvores de decisão	Modelos estatísticos não paramétricos e baseados em regras de partição	Citados entre as técnicas modernas de detecção de padrões (Cunha)
ML sem código (no-code ML)	Interface que testa automaticamente modelos de regressão e indica o de melhor desempenho (por exemplo, R^2), sem programação	Suportes de tubulação; democratização do ML (Oliveira)

Conceito	Definição	Aplicação no evento (palestrante)
Inferência bayesiana	Atualização de crenças (a priori para a posteriori) à medida que chegam novos dados	Projeções durante apurações eleitorais (Cunha)

6.2 IA generativa e modelos de linguagem

Conceito	Definição	Aplicação no evento (palestrante)
Modelo de linguagem de grande porte (LLM)	Modelo treinado em grandes volumes de texto para compreender e gerar linguagem	Uso difundido na plateia; LLMs nacionais do LNCC (Oliveira, Santos)
Agente de IA e sistemas multiagentes	LLM com objetivos, contexto e ferramentas para executar tarefas; vários agentes podem cooperar	Enquete com a plateia; agentes que delegam cálculos a ferramentas (Oliveira)
Assistente industrial	Agente que consulta documentação técnica da planta, manuais e modelos 3D e sugere ações em linguagem natural	Buscas em P&IDs, PFDs e modelos 3D; revisão de modelos de simulação (Oliveira)
IA generativa	Modelos que geram conteúdo novo, como texto, imagens, trajetos ou dados	Traçado automático de tubulações (Oliveira); geração de hipóteses científicas (Cunha)
Alucinação	Saída plausível, mas falsa: referências inventadas ou previsões sem sentido físico fora dos dados	Motivação para restrições de domínio (Nogueira); pergunta sobre agentes (Oliveira)
Viés de dados e de modelos	Distorção sistemática decorrente de dados que cobrem só parte do universo ou de tendências do modelo	Alerta sobre modelos treinados em faixa operacional limitada e sobre LLMs (Oliveira)
Uso responsável da IA	Uso com revisão crítica, proteção de dados confidenciais e atenção à segurança e à qualidade	Recomendações a estudantes e profissionais (Oliveira, Cunha)

6.3 Modelagem híbrida e IA informada pelo domínio

Conceito	Definição	Aplicação no evento (palestrante)
Modelo híbrido (caixa-cinza)	Combinação de equações fenomenológicas com componentes aprendidos dos dados	Smart Monitor (Anzai); leito fixo (Nogueira); biorreator e correção de erros (Cunha)
Viés indutivo	Conhecimento prévio embutido no modelo	Física e termodinâmica como

Conceito	Definição	Aplicação no evento (palestrante)
	para guiar o aprendizado	guia do treino (Nogueira, Cunha)
Equação diferencial universal (UDE)	Equação diferencial em que um termo desconhecido é representado por uma rede neural, treinada pela solução da equação	Equilíbrio de adsorção no termo fonte (Nogueira)
Neural ODE	Rede neural que define a derivada de um sistema dinâmico, integrada numericamente	Citada como outra forma de hibridação (Nogueira)
Incerteza epistêmica	Incerteza decorrente de conhecimento incompleto ou de hipóteses simplificadoras	Termos de um balanço de massa (Nogueira); incerteza de forma do modelo (Cunha)
Arquitetura com forma funcional embutida (PUFFIN)	Rede cuja saída passa por uma equação física conhecida, treinada na propriedade final	Equação de Antoine para pressão de vapor; viscosidade (Nogueira)
Descritores moleculares	Representações computacionais de moléculas: SMILES (texto), impressão digital de Morgan, grafos, imagens 3D	Entradas do modelo multimodal (Nogueira)
Modelo de fundação	Modelo grande e generalista, pré-treinado em muitos dados e adaptável a várias tarefas	MultiPUFFIN, comparado ao ChemBERTa-2 (Nogueira)
Aprendizado multimodal, embeddings e espaço latente	Fusão de diferentes tipos de dado em vetores numéricos num espaço comum de representação	Codificadores transformer, CNN e de grafos unificados (Nogueira)
Retropropagação	Cálculo dos gradientes do erro em relação aos parâmetros da rede para atualizá-los	Treino na propriedade, e não nos parâmetros de Antoine (Nogueira)
Sloppiness de parâmetros	Existência de muitas combinações de parâmetros que produzem o mesmo ajuste	Justificativa para treinar na saída física (Nogueira)

6.4 Aprendizado de máquina científico (SciML)

Conceito	Definição	Aplicação no evento (palestrante)
Aprendizado de máquina científico (SciML)	Integração de ML com modelos físicos e matemáticos para acelerar e melhorar previsões respeitando restrições	Tema central da tarde (Santos, Cunha)

Conceito	Definição	Aplicação no evento (palestrante)
PINN (physics-informed neural network)	Rede cuja função perda inclui o resíduo das equações governantes e as condições de contorno, além dos dados	Ciclone 200 vezes mais rápido que CFD (Santos); virtudes e limites (Cunha)
Rede informada por termodinâmica (TINN)	Rede treinada respeitando equilíbrio de fases e minimização da energia de Gibbs	Substituição do flash em células de CFD (Santos)
Operador neural	Rede que aprende um mapeamento entre espaços de funções, independente da malha	Sensoriamento virtual e super-resolução (Santos, Cunha)
DeepONet	Operador neural com uma rede "branch" (entradas em sensores) e uma "trunk" (coordenadas), combinadas por produto interno	Campo interno em escoamento em golfadas (Santos)
FNO (Fourier Neural Operator)	Operador neural que aprende no espaço de Fourier	Referência de comparação; sensível ao fenômeno de Gibbs (Santos)
Shearlet Neural Operator (SNO)	Operador neural proposto pela equipe do LNCC, baseado na transformada shearlet, sensível a escala e direção	Menor erro em problemas descontínuos e anisotrópicos (Santos)
Teorema de aproximação universal de operadores	Garantia teórica de que certas arquiteturas aproximam qualquer operador contínuo com camadas suficientes	Chen e Chen (1995) para DeepONet; resultado de 2021 para FNO (Santos)
Modelo de ordem reduzida e modelo substituto	Aproximação barata de um modelo de alta fidelidade, válida numa região do domínio	Otimização com milhares de avaliações (Santos, Cunha)
POD e DMD	Decomposições que extraem bases de poucos modos dos dados de simulação (POD, análoga à PCA; DMD, voltada à dinâmica)	Modelagem reduzida vista como aprendizado estatístico (Cunha)
Autoencoder	Rede que comprime dados num espaço latente e os reconstrói	Construção de modelos reduzidos (Santos)
Autoencoder variacional (VAE)	Modelo generativo que aprende uma distribuição latente e gera novas amostras	Fechamento probabilístico de turbulência (Santos)
SINDy	Regressão esparsa que identifica equações	Fechamento de turbulência em

Conceito	Definição	Aplicação no evento (palestrante)
	diferenciais interpretáveis a partir de dados	modelo shell (Santos); panorama de técnicas (Cunha)
ODIL (Optimizing a Discrete Loss)	Otimização do resíduo discreto de um esquema numérico, estimando simultaneamente campo e parâmetros	Comparação com PINN na equação de Burgers (Cunha)
Diferenciação automática	Cálculo exato e automático de derivadas de programas computacionais	Resíduos em PINNs e otimização no ODIL (Cunha)
Viés espectral	Tendência de redes neurais a aprender primeiro as baixas frequências	Limitação das PINNs (Cunha)
Redes neurais hamiltonianas	Arquiteturas que conservam energia por construção	Física imposta pela arquitetura, e não pela perda (Cunha)
Operador de Koopman	Representação linear, em espaço de observáveis, de sistemas dinâmicos não lineares	Técnica da teoria de sistemas dinâmicos baseada em dados (Cunha)
Assimilação de dados	Atualização contínua de modelos com observações	Antecedente histórico do SciML, como na meteorologia (Cunha)
Quantificação de incertezas	Caracterização e propagação das incertezas de dados, parâmetros e forma do modelo	Problema aberto citado por Santos e Cunha; incerteza de medição (Anzai, Feital)
Governança, proveniência e transparência epistêmica	Mecanismos que tornam rastreáveis e verificáveis os conhecimentos e hipóteses gerados por IA	Arquitetura proposta para geração de hipóteses e repositórios (Cunha)

7. Padrões, conceitos recorrentes e conclusões transversais

Sete ideias atravessaram o dia, defendidas por palestrantes de instituições e perfis diferentes.

Padrão recorrente	Como apareceu	Onde
1. Dado sem contexto ou sem qualidade não vira informação	cerca de 99% dos dados ainda por explorar; poucos sensores de composição; dado contextualizado como base da IA; incerteza na base dos sensores	Anzai, Feital, Oliveira, perguntas da manhã
2. O conhecimento físico torna a IA mais confiável	Balanços em gêmeos digitais; UDE e PUFFIN; PINNs e operadores com restrições; física como viés indutivo	Feital, Nogueira, Santos, Cunha

Padrão recorrente	Como apareceu	Onde
3. Extrapolação exige cautela em modelos puramente baseados em dados	Modelos fora da faixa operacional treinada; saturação prevista como parábola; desempenho limitado fora do domínio de treino	Oliveira, Nogueira, Cunha
4. A ferramenta deve seguir o problema e o dado disponível	Modelo condizente com a instrumentação; partir do problema; perguntar se a IA é necessária; ODIL quando o método numérico é bom	Feital, Oliveira, Nogueira, Santos, Cunha
5. Modelos envelhecem e precisam de manutenção	Concept drift, retreino, defasagem detectada via sistemas PI	Anzai, Oliveira
6. Incerteza precisa ser quantificada	Propagação da incerteza de medição; reconciliação com perda como parâmetro; incerteza epistêmica; quantificação de incertezas como problema aberto	Perguntas a Anzai, Feital, Nogueira, Santos, Cunha
7. O engenheiro químico deve ser autor, não só usuário, da IA	Orquestrador de tecnologias; "não sejam apenas utilizadores"; trazer a gramática da engenharia; estatística e programação como base	Oliveira, Nogueira, Santos

Conceitos mais repetidos. Gêmeo digital e sombra digital; sensor virtual; balanços de massa e energia; tempo real; extrapolação; alucinação; incerteza; modelo híbrido; PINN; operador neural; pensamento crítico; uso responsável.

Conclusões principais do dia.

1. O gêmeo digital é apresentado como infraestrutura: integra dados, dá contexto, calcula o estado da planta e oferece a base sobre a qual a IA opera.
2. A indústria já colhe resultados concretos, como detecção de falhas, sensores virtuais em uso contínuo, programação ótima e reduções expressivas de tempo de projeto. O desafio maior passou a ser escalar, sustentar e medir o retorno.
3. Na fronteira científica, a combinação de física e dados reduz a necessidade de dados e de computação e acelera simulações em uma a duas ordens de grandeza. A física imposta só pela função perda continua aproximada.
4. A IA que gera conhecimento e hipóteses exige governança, rastreabilidade, ética e proteção de dados. Isso amplia a interdisciplinaridade da engenharia em direção às ciências humanas.
5. Nenhum palestrante previu a substituição do engenheiro. Todos descreveram um papel ampliado, que depende de fundamentos sólidos (fenômenos de transporte, termodinâmica, estatística, métodos numéricos) e de uso crítico das ferramentas.

8. Principais assuntos discutidos

Os assuntos abaixo concentraram a maior parte do tempo de fala e das perguntas.

1. **Gêmeos digitais: conceito e estágios.** Modelo, sombra e gêmeo digital; gêmeo como contabilidade física e como integrador de dados.

2. **Monitoramento de processos em tempo real.** Detecção e diagnóstico de falhas, sensores virtuais, vida útil remanescente e alarmes.
3. **Integração e escala de soluções digitais.** Plataformas hub, sustentação pela TIC, passagem da pesquisa para a operação e modelos de negócio por assinatura.
4. **Balanços, reconciliação de dados e incertezas de medição.**
5. **Otimização e programação.** Misturas siderúrgicas, estações de compressão, cozedores de açúcar, layout de plantas de hidrogênio verde.
6. **IA na engenharia industrial.** Manutenção preditiva, visão computacional, ML sem código, assistentes industriais baseados em LLMs e IA generativa em projeto.
7. **Futuro da profissão e formação.** Papel do engenheiro químico, empregabilidade de jovens, estatística e programação na formação, pensamento crítico.
8. **Modelagem híbrida.** Hipóteses e incerteza epistêmica, UDEs e arquiteturas com conhecimento de domínio.
9. **Modelos de fundação e aprendizado multimodal** para propriedades termodinâmicas.
10. **Aprendizado de máquina científico.** PINNs, TINNs, operadores neurais (DeepONet, FNO, SNO), ODIL, SINDy e modelos reduzidos.
11. **CFD, termodinâmica e turbulência** acelerados por ML; computação de alto desempenho.
12. **Confiabilidade de modelos, governança da IA científica, repositórios de dados e ética.**

9. Considerações finais

O terceiro dia do XXIII Colóquio de Engenharia Química do PEQ/COPPE/UFRJ formou uma narrativa coerente. Partiu da realidade operacional das indústrias de petróleo, mineração, siderurgia, gás, química e açúcar, passou pelo papel do gêmeo digital como base de dados para a IA e chegou às fronteiras da modelagem híbrida, dos modelos de fundação e do aprendizado de máquina científico.

O evento mostrou a complementaridade entre indústria, empresas de base tecnológica e instituições de pesquisa. As palestras industriais trouxeram problemas reais, dados de operação e exigências de robustez. As acadêmicas trouxeram métodos, garantias teóricas e reflexão crítica sobre limites. As perguntas de alunos e professores aprofundaram temas como incerteza, manutenção de modelos, retorno do investimento, limites das PINNs e governança.

A mensagem comum foi de otimismo responsável. As ferramentas de IA já entregam valor e tendem a se tornar parte do cotidiano da engenharia. Seu bom uso depende do conhecimento de domínio, do pensamento crítico e de compromissos explícitos com qualidade, transparência e ética, temas que o colóquio retomaria no dia seguinte.

10. Fontes

1. Vídeo do evento — "XXIII Colóquio de Engenharia Química – PEQ/COPPE/UFRJ – 05/11/26", YouTube: https://www.youtube.com/watch?v=KHxVFNH2Xso
2. Programação prevista do evento, fornecida pelo solicitante desta análise.
3. Legendas automáticas em português do mesmo vídeo (SRT, extraídas via DownSub — https://downsub.com).

Observação: artigos, empresas, softwares e instituições mencionados ao longo do texto foram citados pelos palestrantes e estão registrados aqui conforme a fala transcrita. Eles não foram consultados diretamente na elaboração deste documento.