Todo o texto a seguir foi gerado pelo Gemini do Google a partir da análise do vídeo no YouTube e da imagem da programação fornecida.

Sumário

1. Estrutura do Evento
2. Índice Cronológico (Atualizado)
3. Conceitos de Inteligência Artificial Abordados
4. Linhas de Raciocínio dos Palestrantes
5. Fontes

---

1. Estrutura do Evento

Com base na imagem da programação fornecida e na análise contínua dos vídeos e transcrições, o evento "Colóquio PEQ 2026 - Engenharia Química na era da IA" foi estruturado para abranger um dia inteiro de discussões. O documento foi atualizado para incluir a Palestra 2, que sucede a Palestra 1 e o período de almoço.

A estrutura consolidada do evento até o momento é a seguinte:

- **08:00 - 08:30:** Credenciamento
- **08:30 - 09:00:** Mesa de abertura (Composição: Prof. João Ramos Torres, Prof.ª Suzana Kahn e Prof. Frederico Kronenberger).
- **09:00 - 09:30:** Coffee Break
- **10:00 - 11:00:** Keynote Speaker - Prof. Álvaro Coutinho (COPPE/UFRJ). Tema: *Recent Advances in Scientific Machine Learning for Coupled Flow and Transport*.
- **11:00 - 12:00:** Palestra 1 - Prof. Henrique Poltronieri Pacheco (NUCAT/UFRJ). Tema: *Machine Learning aplicado ao screening de materiais*.
- **12:00 - 13:30:** Almoço
- **13:30 - 14:30:** Palestra 2 - Prof.ª Amanda Lemette (PUC-Rio). Tema: *IA aplicada à Engenharia de Sistemas de Processos: experiências em diagnóstico de falhas e modelagem híbrida*. **(Foco da presente atualização)**.

- **14:30 - 15:00:** Palestra 3 - Prof. Rafael Dias Mesquita (UFRJ). Tema: *Uso de IA na engenharia de enzimas*.
- **15:30 - 16:00:** Coffee Break
- **16:00 - 17:00:** Sessão de Pôsteres
- **17:00 em diante:** Encerramento

---

2. Índice Cronológico (Atualizado)

O mapeamento a seguir detalha os eventos ocorridos no arquivo de vídeo fornecido, integrando a Keynote Speaker, a Palestra 1 e, agora, a Palestra 2. *(Nota: Os tempos a partir do bloco 3 referem-se à minutagem contínua do arquivo de vídeo fornecido, iniciando na marca de 278 minutos).*

Bloco 1: Keynote Speaker (Prof. Álvaro Coutinho)

- **00:00:00 - 00:15:30:** Introdução e conceito de Simulações de Alta Fidelidade (High-Fidelity) e o desafio do "Outer Loop" via Scientific Machine Learning (SciML).
- **00:15:30 - 00:30:00:** Aplicação 1: Correntes de Turbidez e modelos lineares de Redução de Ordem (DMD).
- **00:30:00 - 00:45:00:** Aplicação 2: Instabilidade de Rayleigh-Bénard e arquitetura não-linear β-VAE.
- **00:45:00 - 00:57:00:** Aplicação 3: Escoamento Multifásico e Operadores Neurais (FNO e DeepONet).
- **00:57:00 - 01:05:00:** Aplicação 4: Agentic AI (Agents4GEOS) e Sessão de Q&A.

Bloco 2: Palestra 1 (Prof. Henrique Poltronieri Pacheco)

- **Início da Palestra e Contextualização:** Contraste entre dados "limpos" e a realidade do experimentalista (dados esparsos e ruidosos).
- **Frente 1 - Tópico 1:** O Software CatS (Catalyst Screener).
- **Frente 1 - Tópico 2:** Despolimerização de Lignina (O Desafio dos Dados Ruins).
- **Frente 2:** Construindo a Base com IA (LLMs como Leitores e Agentes).

- **Sessão de Perguntas e Respostas (Q&A):** Discussões sobre ontologia de dados, modelos de LLMs, alucinações e resgate histórico do uso de redes neurais na COPPE.

Bloco 3: Palestra 2 (Prof.ª Amanda Lemette - PUC-Rio)

- **04:38:07 (278:07) - 04:42:00:** Apresentação da professora Amanda Lemette, introdução ao grupo de pesquisa GAAP (Grupo de Aplicações Avançadas em Processos) da PUC-Rio e introdução aos temas centrais: Detecção/Diagnóstico de Falhas e Modelagem Híbrida.

- **04:42:00 - 04:54:00: Estudo de Caso 1 (Diagnóstico de Falhas no Processo Tennessee Eastman):** A professora explica a motivação de se estudar falhas (prevenção de acidentes como o de Bhopal, segurança, perdas financeiras). Ela detalha o desafio de classificar falhas em uma base de dados de séries temporais maciça (52 variáveis, 5 milhões de amostras).

- **04:54:00 - 05:02:00:** A abordagem inovadora usando o algoritmo GASF (*Gramian Angular Summation Field*) para transformar séries temporais em imagens (mapas de calor) e alimentá-las em Redes Neurais Convolucionais (CNNs). Explicação detalhada de como ajustes na arquitetura da rede (aumento do tamanho do *kernel* e número de filtros) elevaram a precisão para cerca de 90%, superando a literatura existente.

- **05:02:00 - 05:22:00: Estudo de Caso 2 (Modelagem Híbrida - PCINN):** Transição de um problema de "muitos dados" para "poucos dados". A professora introduz as PCINNs (*Physics-Constrained Informed Neural Networks*) para modelar reações de polimerização complexas com apenas 14 experimentos. Ela disseca a Equação da Função de Perda (*Loss Function*), mostrando a soma do erro dos dados com a restrição física (derivada do modelo fenomenológico pelo método dos momentos).

- **05:22:00 - 05:32:00:** Apresentação de resultados de copolimerização. O modelo PCINN supera significativamente a MLP pura e o modelo cinético clássico, corrigindo a trajetória das curvas sem perder a forma física.

- **05:32:00 - 05:43:00: Estudos de Caso 3 e 4:** Aplicação da metodologia PCINN para outros sistemas de polímeros (PBS e PEF), lidando com desafios de dados experimentais incompletos através da adição de termos de penalidade na função de perda (garantindo monotonicidade e restrições de dispersão). Conclusões da palestra.

- **05:43:00 - 05:58:00: Sessão de Perguntas e Respostas (Q&A):**

- **Intervenção sobre Custo Computacional:** Questionamento sobre o tempo de treinamento das arquiteturas. A professora esclarece que as CNNs levaram algumas horas em boas GPUs, mas a etapa das PCINNs é extremamente rápida (quase custo zero computacional) devido à pequena quantidade de dados de laboratório.

- **Intervenção sobre Filosofia da Modelagem (Prof. João):** Uma reflexão profunda sobre até que ponto vale a pena tentar criar modelos físicos perfeitos versus adotar modelos híbridos. A professora concorda que a IA vem como uma ferramenta poderosa para suprir as lacunas onde a física se torna excessivamente complexa ou intratável.

---

3. Conceitos de Inteligência Artificial Abordados

A inclusão da Palestra 2 amplia significativamente o escopo de conceitos de IA do evento, trazendo arquiteturas de Visão Computacional aplicadas a dados sequenciais e Redes Neurais Informadas pela Física:

- **Machine Learning Clássico e IA Generativa (Bloco Anterior):** Random Forest, CatBoost, SVM, Feature Importance, LLMs como Agentes (Claude, GPT), Alucinação e Omissão.

- **Transformação de Séries Temporais em Imagens (GASF):** O *Gramian Angular Summation Field* foi apresentado como uma técnica matemática para converter dados temporais multivariáveis (temperatura, pressão ao longo do tempo) em matrizes visuais (imagens polares). Isso permite que modelos criados para analisar fotos sejam usados em dados industriais.

- **Redes Neurais Convolucionais (CNNs):** Arquiteturas de *Deep Learning* tradicionalmente usadas em Visão Computacional. Na palestra, foram aplicadas para extrair padrões (features) das imagens geradas pelo GASF e diagnosticar qual falha estava ocorrendo na planta química. Foi enfatizada a importância do ajuste de hiperparâmetros, como o tamanho do *kernel* (janela de observação da rede), para melhorar a precisão.

- **Modelagem Híbrida e PCINNs (*Physics-Constrained Informed Neural Networks*):** Diferente das PINNs tradicionais (que embutem as equações diferenciais na própria rede), a PCINN atua como uma ponte. Ela utiliza um modelo fenomenológico clássico (como cinética de reações) para calcular a derivada física e força a rede neural a respeitar essa tendência matemática. Se a rede tentar prever uma curva que desafie a física do reator, ela é penalizada.

- **Engenharia de Função de Perda (*Loss Function Engineering*):** O processo de moldar o aprendizado da máquina compondo uma equação de erro multicritério. A palestrante projetou esquemas mostrando a minimização do L_{total}, composto por:
  - L_{dados}: Erro tradicional entre a predição e o dado real.
  - L_{fisica}: Diferença entre a derivada da rede e a derivada teórica do modelo mecânico.
  - L_{mono}: Penalidade imposta para garantir que propriedades físicas (como a massa molar) não assumam comportamentos absurdos, como diminuir ao longo do tempo em certos processos.
- **Aprendizado por Transferência (*Transfer Learning*) e Redes Siamesas:** Citados como desdobramentos de pesquisa para melhorar a generalização da detecção de falhas de maneira eficiente.

---

4. Linhas de Raciocínio dos Palestrantes

Prof.ª Amanda Lemette (Palestra 2)

- **Linha de Argumentação:** A professora construiu sua fala baseada em uma dicotomia muito presente na engenharia moderna: o contraste entre problemas com "Excesso de Dados" e problemas com "Escassez de Dados". Sua linha de raciocínio foi extremamente lógica e didática.
- **No cenário de excesso de dados (Monitoramento Contínuo):** Ela argumentou que as plantas industriais geram milhões de informações por segundo, tornando impossível a análise humana em tempo hábil para evitar uma falha em cascata. O raciocínio foi: já que redes neurais são ótimas para reconhecer padrões visuais (como o rosto de uma pessoa), por que não "desenhar" o comportamento da planta química como uma imagem e pedir para a IA reconhecer o "rosto" de uma falha? Essa mudança de paradigma gerou ganhos expressivos de acurácia.
- **No cenário de escassez de dados (Pesquisa de Laboratório):** Ela mudou a perspectiva para a bancada química, onde experimentos são caros, lentos e raros (ex: 14 testes para uma tese inteira). A IA tradicional falharia ao tentar aprender com tão poucos pontos. Seu raciocínio evoluiu para a modelagem híbrida: *Os dados dão o nível (a magnitude), a teoria dá a forma.* Integrar a física à rede neural é a única maneira segura

e confiável de interpolar/extrapolar resultados em sistemas químicos com dados limitados.

- **Conclusão da Palestra:** Trabalhar com IA é excelente, mas exige senso crítico do engenheiro. Modelos puramente baseados em dados (data-driven) correm o risco de ferir as leis da termodinâmica. A integração do conhecimento humano (modelos fenomenológicos) com a capacidade computacional (redes neurais) representa o estado da arte e o futuro seguro para a engenharia de processos.

Sessão de Perguntas e Respostas (Q&A) - Bloco 3 O debate seguiu um tom muito cordial, instigante e focado na aplicabilidade prática.

- **Intervenção sobre Custo:** Questionou-se a viabilidade de treinar esses modelos. A palestrante demonstrou transparência ao afirmar que, para grandes volumes (imagens), requer hardware adequado (GPU) e tempo (horas/dias), mas para modelos híbridos (PCINNs), o cálculo é quase instantâneo em qualquer máquina comum.

- **Intervenção Filosófica (Modelagem Física vs. Híbrida):** Um professor provocou a plateia a pensar sobre quando abandonar a teimosia de criar um modelo físico perfeito. A resposta da professora Amanda reforçou o espírito do evento: a IA não vem para substituir o engenheiro ou anular a modelagem física, mas atuar como uma "cola". Onde a equação diferencial falha por simplificações assumidas (idealidades), o dado experimental puxa o modelo para a realidade por meio da rede neural, gerando uma sinergia elegante e funcional.

---

5. Fontes

- **Vídeo Analisado:** https://www.youtube.com/watch?v=yboTkF-94Is&t=22693s