Todo o texto foi gerado pelo Gemini do Google a partir do vídeo no YouTube.

Sumário

1. Estrutura do Evento e Identificação da Palestra
2. Índice Cronológico
3. Conceitos de Inteligência Artificial e Machine Learning
4. Análise Técnica: Equações, Gráficos e Arquiteturas
5. Linhas de Raciocínio e Sessão de Perguntas e Respostas
6. Conclusão Geral
7. Fontes

---

1. Estrutura do Evento e Identificação da Palestra

O trecho analisado corresponde à sessão da tarde do **Colóquio PEQ 2026**, focado no Eixo-temático de Modelagem Híbrida.

- **Palestrante:** Prof. Dr. Fábio Santos (Pesquisador do Laboratório Nacional de Computação Científica - LNCC).
- **Título da Apresentação:** *When Scientific Machine Learning Meets Physics: Modeling Thermodynamics, Fluid Flow, and Turbulence* (Quando o Aprendizado de Máquina Científico Encontra a Física: Modelando Termodinâmica, Escoamento de Fluidos e Turbulência).
- **Contexto:** A palestra aborda a integração de leis da física com algoritmos de Inteligência Artificial (IA) para acelerar simulações, melhorar modelos de fechamento e criar operadores neurais na Engenharia Química e Mecânica dos Fluidos.

---

2. Índice Cronológico

- **05:48:20 - 05:50:00:** Abertura da sessão pelo moderador e apresentação do currículo do palestrante, destacando sua formação na UFRJ, IMPA e atuação no LNCC.
- **05:50:00 - 05:54:50:** Preparação técnica para a apresentação (ajustes de computador, pendrive e projeção dos slides).

- **05:54:50 - 05:58:50:** Início da palestra. Introdução ao LNCC, ao supercomputador Santos Dumont e ao Instituto de Inteligência Artificial do LNCC.

- **05:58:50 - 06:03:50:** Definição de *Scientific Machine Learning* (SciML). O palestrante explica o espectro entre modelos puramente físicos e modelos puramente baseados em dados.

- **06:03:50 - 06:10:00:** Aplicação 1: *Physics-Informed Neural Networks* (PINNs) aplicadas a separadores tipo ciclone. Discussão sobre a inserção das equações de Navier-Stokes na função de perda (loss function).

- **06:10:00 - 06:15:00:** Aplicação 2: Termodinâmica e cálculo de Flash (*GibbsFlashNN*). Uso de IA para minimizar a energia livre de Gibbs e prever o equilíbrio de fases.

- **06:15:00 - 06:28:50:** Operadores Neurais (*Neural Operators*). Transição do mapeamento de pontos para o mapeamento de funções. Apresentação das arquiteturas *DeepONet*, *Fourier Neural Operator* (FNO) e *Shearlet Neural Operator* (SNO). Aplicação em escoamento tipo *slug* (golfadas).

- **06:28:50 - 06:37:00:** Modelos de fechamento (*Closure Models*) para turbulência. Uso de *Variational Autoencoders* (VAE) e SINDy (*Sparse Identification of Nonlinear Dynamics*) para descobrir equações e distribuições probabilísticas.

- **06:37:00 - 06:41:00:** Oportunidades, problemas em aberto e mensagens finais (Take-home messages).

- **06:41:00 - 06:54:45:** Sessão de Perguntas e Respostas (Q&A) com a plateia.

- **06:54:45:** Encerramento do bloco e chamada para o *Coffee Break*.

---

3. Conceitos de Inteligência Artificial e Machine Learning

Durante a apresentação, o palestrante definiu e aplicou diversas ferramentas avançadas de IA:

- **Scientific Machine Learning (SciML):** Uma área de interseção que busca unir o conhecimento prévio (leis de conservação, equações diferenciais) com a capacidade de aprendizado dos dados. O objetivo não é substituir a física, mas complementá-la para acelerar simulações ou cobrir lacunas de conhecimento.

- **Physics-Informed Neural Networks (PINNs):** Redes neurais onde a física é embutida, geralmente, na função de perda (*loss function*). A rede é penalizada se suas previsões violarem leis físicas (como conservação de massa ou momento).

- **Neural Operators (Operadores Neurais):** Diferente das redes neurais clássicas que mapeiam vetores para vetores (espaços de dimensão finita), os operadores neurais mapeiam funções para funções (espaços de dimensão infinita). Isso permite que a rede seja independente da malha (*mesh-free*).
    - **DeepONet:** Arquitetura composta por duas redes: a *Branch net* (que processa a função de entrada) e a *Trunk net* (que processa as coordenadas espaciais/temporais).
    - **Fourier Neural Operator (FNO):** Utiliza a Transformada Rápida de Fourier (FFT) para realizar convoluções no domínio da frequência, capturando padrões globais de forma eficiente.
    - **Shearlet Neural Operator (SNO):** Uma variação apresentada para lidar com descontinuidades (como ondas de choque), onde o FNO falha devido ao fenômeno de Gibbs. Utiliza transformadas que preservam a direcionalidade e a escala.
- **Variational Autoencoders (VAE):** Modelos generativos probabilísticos usados para comprimir dados em um espaço latente e gerar novas amostras. Aplicado para modelar a incerteza em termos de fechamento de turbulência.
- **SINDy (Sparse Identification of Nonlinear Dynamics):** Algoritmo que busca descobrir a equação diferencial governante a partir de dados, promovendo a esparsidade (selecionando apenas os termos matemáticos mais relevantes de uma biblioteca de funções).

---

4. Análise Técnica: Equações, Gráficos e Arquiteturas

O palestrante cruzou o áudio com os recursos visuais de forma bastante didática, detalhando como a matemática se traduz em código e arquitetura de rede:

- **Equações de Navier-Stokes no Ciclone:** O slide exibiu as equações de conservação de massa e momento. O palestrante explicou que, em vez de resolver essas equações numericamente por métodos tradicionais (CFD), os resíduos dessas equações foram adicionados à função de perda da rede neural. O gráfico de resultados mostrou linhas de corrente (*streamlines*) onde a previsão da PINN sobrepôs os dados do CFD tradicional, alcançando uma aceleração de 200 vezes com um erro relativo de apenas 5%.
- **Cálculo de Flash (GibbsFlashNN):** Visualmente, o slide mostrou um problema de otimização: minimizar a energia livre de Gibbs (G) sujeito a restrições de balanço de massa. A arquitetura da rede foi dividida em duas etapas: um classificador (para decidir se o sistema tem 1 ou 2 fases) e um regressor (para calcular as frações molares). O palestrante destacou que a termodinâmica entrou como uma restrição rígida (*hard constraint*) no treinamento.

- **Arquitetura DeepONet para Escoamento Slug:** O esquema visual mostrou dados de sensores (séries temporais) entrando na *Branch net* e coordenadas espaciais entrando na *Trunk net*. O palestrante explicou que o objetivo era reconstruir o campo de velocidade e fração de vazio entre dois sensores físicos em uma tubulação, criando um "Gêmeo Digital" (*Digital Twin*) rápido para monitoramento.

- **Comparação FNO vs. SNO:** Gráficos de erro L_2 foram projetados comparando o FNO e o SNO em problemas com choques (Equação de Burgers). O palestrante apontou visualmente para as oscilações geradas pelo FNO (fenômeno de Gibbs) nas descontinuidades e mostrou como o SNO, por ter sensibilidade direcional, conseguiu eliminar essas oscilações, reduzindo o erro significativamente.

---

5. Linhas de Raciocínio e Sessão de Perguntas e Respostas

Linha de Argumentação do Palestrante: A narrativa central do Prof. Fábio foi que a IA pura (caixa preta) requer muitos dados e carece de interpretabilidade, enquanto a simulação clássica é precisa, mas computacionalmente cara. A linha de raciocínio defendeu que a inserção da física na IA atua como um regularizador poderoso, permitindo treinar modelos com menos dados, garantindo que as previsões respeitem as leis da natureza e acelerando a tomada de decisão na engenharia.

Sessão de Perguntas e Respostas (Q&A):

1. **Pergunta de Juan:** Questionou sobre as entradas e saídas do modelo de cálculo de Flash e como isso se integraria a uma simulação CFD completa.

    - *Resposta:* O palestrante explicou que, em uma simulação CFD multifásica, o cálculo de Flash precisa ser feito em cada célula da malha a cada passo de tempo, o que é o maior gargalo computacional. O modelo de IA substitui esse cálculo local (recebendo Pressão, Temperatura e Composição global, e retornando as frações das fases), acelerando a simulação global.

2. **Pergunta de Gustavo:** Fez uma provocação técnica sobre as PINNs, argumentando que colocar a física na função de perda é uma restrição "fraca" (*soft constraint*) e perguntou se não haveria alternativas melhores, já que as PINNs têm dificuldades com problemas multiescala.

    - *Resposta:* O palestrante concordou plenamente, mantendo um tom cordial e científico. Ele confirmou que as PINNs não são uma "bala de prata" e sofrem com problemas multiescala. No entanto, defendeu que para problemas inversos (descobrir parâmetros a partir de dados esparsos), as PINNs ainda são ferramentas excelentes. Mencionou também que a comunidade está caminhando para abordagens híbridas, unindo Elementos Finitos com PINNs.

3. **Pergunta de Hugo:** Pediu esclarecimentos sobre a aplicação no escoamento tipo *slug* perguntando como o modelo determina o número de fases e como isso se compara a uma simulação CFD 3D.

    - *Resposta:* O palestrante esclareceu que aquele modelo específico era 1D, focado em prever o comportamento ao longo da tubulação entre dois sensores. O objetivo não era substituir o CFD 3D detalhado, mas fornecer uma resposta em tempo real (segundos) baseada em dados de sensores, atuando como um modelo substituto (*surrogate*) para monitoramento operacional.

---

6. Conclusão Geral

O bloco demonstrou de forma clara o estado da arte na aplicação de Inteligência Artificial na Engenharia Química e Mecânica. A conclusão geral da apresentação e das discussões é que a IA não veio para substituir os métodos numéricos tradicionais ou o conhecimento físico estabelecido. Pelo contrário, o futuro reside na **Modelagem Híbrida** (*Scientific Machine Learning*), onde a física orienta o aprendizado de máquina, resultando em modelos mais rápidos, robustos, generalizáveis e fisicamente consistentes, essenciais para a nova era da engenharia industrial.

---

7. Fontes

- Vídeo original do YouTube: https://www.youtube.com/watch?v=KHxVFNH2Xso&t=2s