Todo o texto a seguir foi gerado pelo Gemini do Google a partir da análise do vídeo no YouTube e da imagem da programação fornecida.

Sumário

1. Estrutura do Evento
2. Índice Cronológico (Atualizado)
3. Conceitos de Inteligência Artificial Abordados
4. Linhas de Raciocínio dos Palestrantes
5. Fontes

---

1. Estrutura do Evento

Com base na imagem da programação fornecida e na análise contínua dos vídeos e transcrições, o evento "Colóquio PEQ 2026 - Engenharia Química na era da IA" foi estruturado para abranger um dia inteiro de discussões. O documento foi atualizado para incluir a **Palestra 1**, que sucede a Keynote Speaker.

A estrutura consolidada do evento até o momento é a seguinte:

- **08:00 - 08:30:** Credenciamento
- **08:30 - 09:00:** Mesa de abertura (Composição: Prof. João Ramos Torres, Prof.ª Suzana Kahn e Prof. Frederico Kronenberger).
- **09:00 - 09:30:** Coffee Break
- **10:00 - 11:00:** Keynote Speaker - Prof. Álvaro Coutinho (COPPE/UFRJ). Tema: *Recent Advances in Scientific Machine Learning for Coupled Flow and Transport*.
- **11:00 - 12:00:** Palestra 1 - Prof. Henrique Poltronieri Pacheco (NUCAT/UFRJ). Tema: *Aprendizado de máquina aplicado ao screening de materiais*. **(Foco da presente atualização)**.
- **12:00 - 13:30:** Almoço
- **13:30 - 14:30:** Palestra 2 - Amanda Lemette (Tema: IA aplicada à Engenharia de Sistemas de Processos).

- **14:30 - 15:30:** Palestra 3 - Rafael Dias Mesquita (Tema: Uso de IA na engenharia de enzimas).
- **15:30 - 16:00:** Coffee Break
- **16:00 - 17:00:** Sessão de Pôsteres
- **17:00 em diante:** Encerramento

---

2. Índice Cronológico (Atualizado)

O mapeamento a seguir detalha os eventos ocorridos no arquivo de vídeo fornecido, integrando a Keynote Speaker e a Palestra 1:

Bloco 1: Keynote Speaker (Prof. Álvaro Coutinho)

- **00:00:00 - 00:15:30:** Introdução e conceito de Simulações de Alta Fidelidade (High-Fidelity) e o desafio do "Outer Loop" via Scientific Machine Learning (SciML).
- **00:15:30 - 00:30:00:** Aplicação 1: Correntes de Turbidez e modelos lineares de Redução de Ordem (DMD).
- **00:30:00 - 00:45:00:** Aplicação 2: Instabilidade de Rayleigh-Bénard e arquitetura não-linear β-VAE.
- **00:45:00 - 00:57:00:** Aplicação 3: Escoamento Multifásico e Operadores Neurais (FNO e DeepONet).
- **00:57:00 - 01:05:00:** Aplicação 4: Agentic AI (Agents4GEOS) e Sessão de Q&A.

Bloco 2: Palestra 1 (Prof. Henrique Poltronieri Pacheco)

- **Início da Palestra e Contextualização:** O Prof. Rui de Paula apresenta o Prof. Henrique. Henrique inicia sua fala contrastando sua abordagem com a da palestra anterior. Enquanto a Keynote focou em dados "limpos" gerados por equações físicas, sua palestra foca na realidade do experimentalista de bancada: dados esparsos, heterogêneos e ruidosos. O objetivo é "evangelizar" o uso de Machine Learning (ML) para engenheiros de reações e catálise.
- **Frente 1 - Tópico 1: O Software CatS (Catalyst Screener):** Apresentação da ferramenta desenvolvida no NUCAT para prever o desempenho de catalisadores heterogêneos. O palestrante exibe gráficos de paridade (Predito vs. Observado)

comparando algoritmos (Random Forest, CatBoost, SVM, MLP) treinados com um banco de dados de mais de 15.000 pontos extraídos manualmente da literatura. O Random Forest obteve R^2 superior a 0.94. Ele destaca o gráfico de *Feature Importance* (Importância de Variáveis), mostrando que o modelo "redescobriu" a química (ex: a temperatura e a presença de Níquel são os fatores mais cruciais na reforma a vapor do metano).

- **Frente 1 - Tópico 2: Despolimerização de Lignina (O Desafio dos Dados Ruins):** Transição para um projeto mais complexo em parceria com o INT. A lignina possui dados muito mais escassos (apenas 722 experimentos) e heterogêneos. Os gráficos mostram que o desempenho dos modelos caiu drasticamente (R^2 ~0.57). O palestrante introduz o conceito de "Ontologia" (a dificuldade de padronizar nomenclaturas químicas na literatura). Apesar do baixo R^2, o modelo gerou *insights* valiosos, como o gráfico de violino que provou que a escolha do solvente (polar aprótico) impacta mais o rendimento do que o próprio metal catalítico.

- **Frente 2: Construindo a Base com IA (LLMs como Leitores):** Para resolver o gargalo da extração manual de dados (que levou anos), o palestrante apresenta um *pipeline* (fluxograma) usando Modelos de Linguagem (LLMs como Claude e GPT) atuando como agentes autônomos para ler PDFs de artigos científicos e extrair parâmetros (Agente Catalisador, Agente Metal/Suporte, Agente de Normalização).

- **Desafios da IA Generativa:** Exibição de gráficos de barras comparando os erros do Claude vs. GPT. O palestrante define os problemas de *Alucinação* (falso positivo - a IA inventa um dado) e *Omissão* (falso negativo - a IA não encontra o dado).

- **Sessão de Perguntas e Respostas (Q&A):**
  - **Intervenção de Igor (Doutorando):** Questiona sobre a padronização (ontologia) e como lidar com a diversidade de nomenclaturas.
  - **Intervenção de Felipe:** Pergunta sobre quais modelos específicos de LLM foram testados.
  - **Intervenção de Ana:** Levanta uma questão crítica sobre como confiar nos dados extraídos por IA, dado o risco de alucinações.
  - **Comentário Histórico:** Um professor da plateia relembra, de forma enriquecedora, o trabalho pioneiro da Prof.ª Vera Salim, que já aplicava redes neurais na catálise no início dos anos 90, demonstrando a evolução histórica do tema na COPPE.

3. Conceitos de Inteligência Artificial Abordados

A Palestra 1 introduziu conceitos focados em Machine Learning Clássico e IA Generativa aplicada à extração de dados:

- **Machine Learning Clássico (Modelos Preditivos):**
  - **Random Forest (Florestas Aleatórias) e CatBoost:** Algoritmos baseados em árvores de decisão. Foram apresentados como os mais robustos para lidar com dados experimentais tabulares, superando redes neurais nesse contexto específico.
  - **Support Vector Machines (SVM) e Multilayer Perceptron (MLP):** Testados como *benchmarks*, mas apresentaram desempenho inferior ou maior instabilidade com dados esparsos.
- **Feature Importance (Importância de Variáveis):** Uma técnica de interpretabilidade de IA. O palestrante exibiu gráficos de barras horizontais gerados pelo modelo para explicar *por que* a IA tomou certa decisão, provando que a máquina aprendeu princípios químicos fundamentais (ex: a relevância térmica em reações endotérmicas) sem ter sido explicitamente programada com equações físicas.
- **Ontologia de Dados:** O desafio de estruturar o conhecimento. Na IA, refere-se à necessidade de criar um vocabulário padronizado para que a máquina entenda que termos diferentes na literatura (ex: diferentes formas de descrever um suporte catalítico) referem-se à mesma entidade química.
- **LLMs (Large Language Models) e Agentic AI:** Uso de modelos como Claude e GPT não para geração de texto livre, mas inseridos em um *pipeline* de extração de dados (Data Mining). O esquema projetado mostrou agentes especializados trabalhando em cadeia para ler PDFs e gerar tabelas estruturadas.
- **Métricas de Erro em IA Generativa:**
  - **Alucinação (Falso Positivo):** Quando o LLM afirma que um catalisador foi usado no artigo, mas ele não estava lá (comum em compostos complexos).
  - **Omissão (Falso Negativo):** Quando o dado existe no texto, mas a IA falha em extraí-lo (comum quando a informação está implícita).
- **Guardrails e Detecção de Outliers:** Em resposta às perguntas, foi discutido o uso de testes estatísticos (como o teste de Hotelling) para atuar como "filtros de

segurança" (*guardrails*), identificando anomalias nos dados extraídos pela IA antes que eles alimentem os modelos preditivos.

---

4. Linhas de Raciocínio dos Palestrantes

Prof. Henrique Poltronieri Pacheco (Palestra 1)

- **Linha de Argumentação:** A apresentação seguiu uma linha pragmática e realista, focada no lema *"Garbage in, garbage out"* (Lixo entra, lixo sai). Ele construiu seu argumento mostrando primeiro um caso de sucesso (CatS), onde dados abundantes geraram previsões excelentes. Em seguida, contrastou com um caso difícil (Lignina), provando que a IA não faz milagres se os dados experimentais forem escassos ou mal reportados.

- **Evolução do Raciocínio:** Ele desmistificou a IA para o público experimentalista. Mostrou que o maior gargalo não é treinar o modelo, mas sim construir a base de dados (que levou anos de trabalho manual). A evolução natural de sua pesquisa foi, portanto, usar a própria IA (LLMs) para automatizar a leitura de artigos, fechando o ciclo de desenvolvimento.

- **Conclusão da Palestra:** A máquina é uma excelente ferramenta de triagem (*screening*) que poupa tempo e dinheiro em laboratório (evitando testes com metais caros que não funcionarão). Contudo, o espírito crítico, a intuição química e a validação humana continuam sendo o núcleo insubstituível da pesquisa.

Sessão de Perguntas e Respostas (Q&A) O debate manteve um tom altamente colaborativo e acadêmico, refletindo o engajamento da plateia com os desafios práticos da IA.

- **Intervenções de Igor e Felipe:** Focaram na mecânica da construção de dados. O Prof. Henrique respondeu de forma transparente, admitindo que a padronização (ontologia) é o calcanhar de Aquiles da área e detalhando as ferramentas (Claude/GPT) usadas para tentar contornar isso.

- **Intervenção de Ana:** Trouxe o ponto mais crítico sobre a confiança na IA (alucinações). A resposta do palestrante foi ponderada: não se deve confiar cegamente. A solução é criar *pipelines* com validação estatística e manter o pesquisador no controle das decisões finais.

- **Resgate Histórico:** A menção ao trabalho da Prof.ª Vera Salim nos anos 90 serviu como um belo fechamento, honrando a tradição da instituição e mostrando que a busca por integrar computação e engenharia química é um esforço contínuo e geracional.

---

5. Fontes

- **Vídeo Analisado:** https://www.youtube.com/watch?v=yboTkF-94Is&t=22693s